

Deskriptive Analyse von Verkehrsunfällen mit Fokus auf die relative Unfallschwere

Mathangi Pirasanthan

Miriam Mack

Jasmin Hauschild

2026-01-12

Imports

```
# label: imports-libraries
library(tidyverse)
library(skimr)
library(lubridate)
library(ggplot2)
library(patchwork)
library(dplyr)
library(gt)
```

Warning: package 'gt' was built under R version 4.5.2

1 Formulierung der Fragestellung

Ausgangspunkt unserer Analyse ist ein umfangreicher Datensatz zu Verkehrsunfällen. Dieser enthält zeitliche Informationen, Angaben zu den Umgebungsbedingungen wie Wetter und Lichtverhältnisse sowie Merkmale zur Art des Unfalls und zur Schwere der Verletzungen. Besonders interessant ist dabei die Kombination aus zeitlichen, infrastrukturellen und situativen Variablen. Denn Verkehrsunfälle entstehen in der Regel nicht durch einen einzelnen Faktor, sondern durch das Zusammenspiel mehrerer Rahmenbedingungen. Wir untersuchen, ob sich aus diesen Daten systematische Muster erkennen lassen, die über reine Unfallhäufigkeiten hinausgehen und Hinweise auf typische Risikosituationen geben.

Konkret lautet unsere Fragestellung: Welche äußeren Bedingungen und Unfalleigenschaften stehen in einem erkennbaren Zusammenhang mit der Schwere von Verkehrsunfällen? Im Fokus steht, ob bestimmte Kombinationen aus Wetterlage, Lichtverhältnissen, Unfalltyp, Wochentag

und Verkehrssituation häufiger mit Verletzungen oder schweren Unfällen verbunden sind als andere. Das Ziel der Analyse ist nicht die Vorhersage einzelner Unfälle, sondern ein besseres Verständnis dafür, unter welchen Bedingungen Unfälle eher glimpflich verlaufen und wann das Risiko für Verletzungen deutlich ansteigt.

Auf Grundlage allgemeiner Annahmen zur Verkehrssicherheit erwarten wir, dass ungünstige Sichtverhältnisse wie Dunkelheit oder Regen sowie komplexe Verkehrssituationen wie Kreuzungen oder Abbiegevorgänge mit einer höheren Unfall- und Verletzungsschwere einhergehen. Zudem vermuten wir, dass in den Wintermonaten insgesamt mehr Unfälle auftreten, da Faktoren wie Schnee, Eis und eine geringere Tageslichtdauer die Fahrsituation zusätzlich erschweren. Gleichzeitig gehen wir davon aus, dass ein großer Anteil der Unfälle unter scheinbar günstigen Bedingungen wie Tageslicht und trockener Fahrbahn passiert. Diese Annahme begründet sich darin, dass unter solchen Bedingungen das Verkehrsaufkommen in der Regel deutlich höher ist, etwa im Berufsverkehr oder im alltäglichen Individualverkehr, wodurch es trotz guter Sicht und Fahrbahnverhältnisse häufiger zu Unfällen kommt. Wir erwarten jedoch, dass diese Unfälle überwiegend mild verlaufen, da bessere Sicht, höhere Reaktionsmöglichkeiten und insgesamt kontrollierbarere Fahrsituationen das Risiko schwerer Verletzungen reduzieren. Die Analyse soll zeigen, ob sich diese Erwartungen im Datensatz bestätigen lassen oder ob einzelne Faktoren überschätzt werden und andere, bislang weniger beachtete Einflüsse eine größere Rolle spielen.

2 Laden der Daten

In diesem Abschnitt wird der Datensatz in die R-Umgebung geladen und einer ersten explorativen Sichtprüfung unterzogen. Das Ziel besteht darin, die grundlegende Struktur der Daten zu erfassen, zentrale Variablentypen zu identifizieren und Auffälligkeiten zu erkennen, welche die Weiterverarbeitung erschweren könnten. Diese initiale Bestandsaufnahme bildet die Grundlage für die nachfolgenden Bereinigungs- und Transformationsschritte. Darüber hinaus dient sie dazu, notwendige Anpassungen an Datentyp, Kodierung und fehlenden Werten zu ermitteln.

```
dataset <- read.table(  
  file = "dataset_traffic_accidents.csv", sep = ",", header=T, stringsAsFactors = F  
)  
  
glimpse(dataset)
```

Rows: 209,306

Columns: 24

\$ crash_date	<chr> "07/29/2023 01:00:00 PM", "08/13/2023 12~
\$ traffic_control_device	<chr> "TRAFFIC SIGNAL", "TRAFFIC SIGNAL", "TRA~
\$ weather_condition	<chr> "CLEAR", "CLEAR", "CLEAR", "CLEAR", "CLE~

```

$ lighting_condition      <chr> "DAYLIGHT", "DARKNESS, LIGHTED ROAD", "D~
$ first_crash_type        <chr> "TURNING", "TURNING", "REAR END", "ANGLE~
$ trafficway_type         <chr> "NOT DIVIDED", "FOUR WAY", "T-INTERSECTI~
$ alignment               <chr> "STRAIGHT AND LEVEL", "STRAIGHT AND LEVE~
$ roadway_surface_cond    <chr> "UNKNOWN", "DRY", "DRY", "DRY", "UNKNOWN~
$ road_defect              <chr> "UNKNOWN", "NO DEFECTS", "NO DEFECTS", "~
$ crash_type              <chr> "NO INJURY / DRIVE AWAY", "NO INJURY / D~
$ intersection_related_i  <chr> "Y", "Y", "Y", "Y", "Y", "N", "Y", "Y", ~
$ damage                  <chr> "$501 - $1,500", "OVER $1,500", "$501 - ~
$ prim_contributory_cause <chr> "UNABLE TO DETERMINE", "IMPROPER TURNING~
$ num_units               <int> 2, 2, 3, 2, 2, 1, 2, 2, 2, 2, 1, 2, 2, 2~
$ most_severe_injury      <chr> "NO INDICATION OF INJURY", "NO INDICATIO~
$ injuries_total          <dbl> 0, 0, 0, 5, 0, 2, 0, 1, 0, 0, 0, 0, 0, 0~
$ injuries_fatal          <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
$ injuries_incapacitating <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
$ injuries_non_incapacitating <dbl> 0, 0, 0, 5, 0, 2, 0, 1, 0, 0, 0, 0, 0, 0~
$ injuries_reported_not_evident <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
$ injuries_no_indication  <dbl> 3, 2, 3, 0, 3, 0, 2, 1, 3, 4, 1, 2, 2, 2~
$ crash_hour              <int> 13, 0, 10, 19, 14, 0, 11, 14, 18, 17, 20~
$ crash_day_of_week       <int> 7, 1, 5, 4, 7, 4, 3, 4, 2, 5, 5, 4, 5, 4~
$ crash_month             <int> 7, 8, 12, 8, 8, 9, 12, 9, 6, 9, 9, 11, 7~

```

```
str(dataset)
```

```

'data.frame':  209306 obs. of  24 variables:
 $ crash_date           : chr  "07/29/2023 01:00:00 PM" "08/13/2023 12:11:00 AM" "12~
 $ traffic_control_device : chr  "TRAFFIC SIGNAL" "TRAFFIC SIGNAL" "TRAFFIC SIGNAL" "TI~
 $ weather_condition     : chr  "CLEAR" "CLEAR" "CLEAR" "CLEAR" ...
 $ lighting_condition    : chr  "DAYLIGHT" "DARKNESS, LIGHTED ROAD" "DAYLIGHT" "DAYLI~
 $ first_crash_type      : chr  "TURNING" "TURNING" "REAR END" "ANGLE" ...
 $ trafficway_type       : chr  "NOT DIVIDED" "FOUR WAY" "T-INTERSECTION" "FOUR WAY"~
 $ alignment             : chr  "STRAIGHT AND LEVEL" "STRAIGHT AND LEVEL" "STRAIGHT A~
 $ roadway_surface_cond  : chr  "UNKNOWN" "DRY" "DRY" "DRY" ...
 $ road_defect           : chr  "UNKNOWN" "NO DEFECTS" "NO DEFECTS" "NO DEFECTS" ...
 $ crash_type            : chr  "NO INJURY / DRIVE AWAY" "NO INJURY / DRIVE AWAY" "NO~
 $ intersection_related_i : chr  "Y" "Y" "Y" "Y" ...
 $ damage                : chr  "$501 - $1,500" "OVER $1,500" "$501 - $1,500" "OVER $~
 $ prim_contributory_cause : chr  "UNABLE TO DETERMINE" "IMPROPER TURNING/NO SIGNAL" "FU~
 $ num_units             : int  2 2 3 2 2 1 2 2 2 2 ...
 $ most_severe_injury    : chr  "NO INDICATION OF INJURY" "NO INDICATION OF INJURY" "I~
 $ injuries_total        : num  0 0 0 5 0 2 0 1 0 0 ...
 $ injuries_fatal        : num  0 0 0 0 0 0 0 0 0 0 ...

```

```

$ injuries_incapacitating      : num  0 0 0 0 0 0 0 0 0 0 ...
$ injuries_non_incapacitating  : num  0 0 0 5 0 2 0 1 0 0 ...
$ injuries_reported_not_evident: num  0 0 0 0 0 0 0 0 0 0 ...
$ injuries_no_indication       : num  3 2 3 0 3 0 2 1 3 4 ...
$ crash_hour                   : int   13 0 10 19 14 0 11 14 18 17 ...
$ crash_day_of_week            : int    7 1 5 4 7 4 3 4 2 5 ...
$ crash_month                  : int    7 8 12 8 8 9 12 9 6 9 ...

```

```

# optional
head(dataset, 3)

```

```

      crash_date traffic_control_device weather_condition
1 07/29/2023 01:00:00 PM      TRAFFIC SIGNAL      CLEAR
2 08/13/2023 12:11:00 AM      TRAFFIC SIGNAL      CLEAR
3 12/09/2021 10:30:00 AM      TRAFFIC SIGNAL      CLEAR

      lighting_condition first_crash_type trafficway_type      alignment
1      DAYLIGHT      TURNING      NOT DIVIDED STRAIGHT AND LEVEL
2 DARKNESS, LIGHTED ROAD      TURNING      FOUR WAY STRAIGHT AND LEVEL
3      DAYLIGHT      REAR END  T-INTERSECTION STRAIGHT AND LEVEL

      roadway_surface_cond road_defect      crash_type
1      UNKNOWN      UNKNOWN NO INJURY / DRIVE AWAY
2      DRY      NO DEFECTS NO INJURY / DRIVE AWAY
3      DRY      NO DEFECTS NO INJURY / DRIVE AWAY

      intersection_related_i      damage      prim_contributory_cause num_units
1      Y $501 - $1,500      UNABLE TO DETERMINE      2
2      Y      OVER $1,500 IMPROPER TURNING/NO SIGNAL      2
3      Y $501 - $1,500      FOLLOWING TOO CLOSELY      3

      most_severe_injury injuries_total injuries_fatal injuries_incapacitating
1 NO INDICATION OF INJURY      0      0      0
2 NO INDICATION OF INJURY      0      0      0
3 NO INDICATION OF INJURY      0      0      0

      injuries_non_incapacitating injuries_reported_not_evident
1      0      0
2      0      0
3      0      0

      injuries_no_indication crash_hour crash_day_of_week crash_month
1      3      13      7      7
2      2      0      1      8
3      3      10     5     12

```

```
dim(dataset)
```

```
[1] 209306      24
```

```
# View funktioniert nur in der Konsole, nicht in qmd.  
# view(dataset)
```

```
colSums(is.na(dataset))
```

crash_date	0	traffic_control_device	0
weather_condition	0	lighting_condition	0
first_crash_type	0	trafficway_type	0
alignment	0	roadway_surface_cond	0
road_defect	0	crash_type	0
intersection_related_i	0	damage	0
prim_contributory_cause	0	num_units	0
most_severe_injury	0	injuries_total	0
injuries_fatal	0	injuries_incapacitating	0
injuries_non_incapacitating	0	injuries_reported_not_evident	0
injuries_no_indication	0	crash_hour	0
crash_day_of_week	0	crash_month	0

```
sapply(dataset, class)
```

crash_date	traffic_control_device
"character"	"character"
weather_condition	lighting_condition
"character"	"character"

first_crash_type	trafficway_type
"character"	"character"
alignment	roadway_surface_cond
"character"	"character"
road_defect	crash_type
"character"	"character"
intersection_related_i	damage
"character"	"character"
prim_contributory_cause	num_units
"character"	"integer"
most_severe_injury	injuries_total
"character"	"numeric"
injuries_fatal	injuries_incapacitating
"numeric"	"numeric"
injuries_non_incapacitating	injuries_reported_not_evident
"numeric"	"numeric"
injuries_no_indication	crash_hour
"numeric"	"integer"
crash_day_of_week	crash_month
"integer"	"integer"

```
table(dataset$weather_condition)
```

BLOWING SAND, SOIL, DIRT	BLOWING SNOW	CLEAR
1	127	164700
CLOUDY/OVERCAST	FOG/SMOKE/HAZE	FREEZING RAIN/DRIZZLE
7533	360	510
OTHER	RAIN	SEVERE CROSS WIND GATE
627	21703	32
SLEET/HAIL	SNOW	UNKNOWN
308	6871	6534

Nach dem Import des Datensatzes wurde mithilfe von `glimpse()` eine erste Bestandsaufnahme durchgeführt. Die Daten liegen als Mischung aus numerischen (`int`, `dbl`) und textbasierten (`chr`) Variablen vor. Dabei zeigten sich mehrere Auffälligkeiten, die eine direkte Verwendung für die Analyse erschweren und aufzeigen, wo eine Bereinigung notwendig ist.

Fehlerhafte Datentypen: Die Zeitstempel (`crash_date`) werden beim Import als Zeichenkette interpretiert. Für zeitliche Analysen wie Wochentag oder Tageszeit ist jedoch eine Konvertierung in ein echtes Date-Time-Objekt erforderlich, aus dem die relevanten Komponenten extrahiert werden können. Obwohl die Variablen `crash_hour`, `crash_day_of_week` und

`crash_month` bereits im Datensatz vorhanden sind, werden diese bewusst nicht verwendet. Stattdessen erfolgt die Ableitung direkt aus `crash_date`, um eine einheitliche zeitliche Referenz sicherzustellen und Interpretationsprobleme zu vermeiden. Beispielsweise ist im US-amerikanischen Kodierungsschema der Wert 1 dem Sonntag zugeordnet, während im vorliegenden Analysekontext eine Zuordnung von 1 zu Montag intuitiver ist. Zudem sind Date-Time-Objekte für weiterführende zeitliche Auswertungen robuster und flexibler als rein numerische Kodierungen. Darüber hinaus liegen logisch geordnete Daten wie die Schadenshöhe (`damage`) sowie nominale Kategorien (z. B. `weather_condition`) noch als ungeordnete Zeichenketten vor und müssen im Bereinigungsschritt in geeignete Faktoren (`factor`) überführt werden.

Versteckte fehlende Werte: Mehrere Variablen enthalten Platzhalter für fehlende Informationen, die nicht als technisches NA kodiert sind. Dazu zählen Einträge wie UNKNOWN (z. B. bei `road_defect`) oder UNABLE TO DETERMINE (bei `prim_contributory_cause`). Diese Werte müssen identifiziert und einheitlich behandelt werden, da sie sonst Analysen verzerren können. Eine Übersicht der fehlenden Werte zeigt zudem, dass im Rohdatensatz keine Einträge als technisches NA vorliegen und Informationslücken ausschließlich über Platzhalterwerte abgebildet sind.

Analysebedingte Umcodierung: Die Variable `most_severe_injury` liegt als detaillierte textuelle Beschreibung vor. Für die Fragestellung dieser Arbeit ist diese Granularität jedoch nicht erforderlich. Stattdessen muss die Variable im Transformationsschritt zu einer binären Kenngröße (Verletzung ja/nein) zusammengefasst werden, um die relative Unfallschwere einfach und vergleichbar abzubilden.

3 Bereinigen und Transformieren der Daten

In diesem Kapitel wird der Datensatz gezielt bereinigt und für die anschließende Analyse aufbereitet. Das Ziel besteht darin, die Rohdaten in eine konsistente, analysetaugliche Struktur zu überführen. Dazu gehört das Entfernen von Duplikaten, die Korrektur und Vereinheitlichung von Datentypen, die Behandlung fehlender oder unklar kodierter Werte sowie die gezielte Reduktion und Aggregation von Variablen. Darüber hinaus werden neue Merkmale abgeleitet, die zentrale Aspekte des Unfallgeschehens wie den Zeitbezug und die Unfallschwere abbilden. Durch die vorgenommenen Transformationen wird sichergestellt, dass die folgenden Auswertungen inhaltlich interpretierbar und statistisch belastbar sind.

```
glimpse(dataset)
```

```
Rows: 209,306
Columns: 24
$ crash_date           <chr> "07/29/2023 01:00:00 PM", "08/13/2023 12~
$ traffic_control_device <chr> "TRAFFIC SIGNAL", "TRAFFIC SIGNAL", "TRA~
$ weather_condition     <chr> "CLEAR", "CLEAR", "CLEAR", "CLEAR", "CLE~
```

```

$ lighting_condition      <chr> "DAYLIGHT", "DARKNESS, LIGHTED ROAD", "D~
$ first_crash_type        <chr> "TURNING", "TURNING", "REAR END", "ANGLE~
$ trafficway_type         <chr> "NOT DIVIDED", "FOUR WAY", "T-INTERSECTI~
$ alignment               <chr> "STRAIGHT AND LEVEL", "STRAIGHT AND LEVE~
$ roadway_surface_cond    <chr> "UNKNOWN", "DRY", "DRY", "DRY", "UNKNOWN~
$ road_defect              <chr> "UNKNOWN", "NO DEFECTS", "NO DEFECTS", "~
$ crash_type              <chr> "NO INJURY / DRIVE AWAY", "NO INJURY / D~
$ intersection_related_i  <chr> "Y", "Y", "Y", "Y", "Y", "N", "Y", "Y", ~
$ damage                  <chr> "$501 - $1,500", "OVER $1,500", "$501 - ~
$ prim_contributory_cause <chr> "UNABLE TO DETERMINE", "IMPROPER TURNING~
$ num_units               <int> 2, 2, 3, 2, 2, 1, 2, 2, 2, 2, 1, 2, 2, 2~
$ most_severe_injury      <chr> "NO INDICATION OF INJURY", "NO INDICATIO~
$ injuries_total          <dbl> 0, 0, 0, 5, 0, 2, 0, 1, 0, 0, 0, 0, 0, 0~
$ injuries_fatal          <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
$ injuries_incapacitating <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
$ injuries_non_incapacitating <dbl> 0, 0, 0, 5, 0, 2, 0, 1, 0, 0, 0, 0, 0, 0~
$ injuries_reported_not_evident <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
$ injuries_no_indication  <dbl> 3, 2, 3, 0, 3, 0, 2, 1, 3, 4, 1, 2, 2, 2~
$ crash_hour              <int> 13, 0, 10, 19, 14, 0, 11, 14, 18, 17, 20~
$ crash_day_of_week       <int> 7, 1, 5, 4, 7, 4, 3, 4, 2, 5, 5, 4, 5, 4~
$ crash_month             <int> 7, 8, 12, 8, 8, 9, 12, 9, 6, 9, 9, 11, 7~

```

```
skim(dataset)
```

Tabelle 1: Data summary

Name	dataset
Number of rows	209306
Number of columns	24
Column type frequency:	
character	14
numeric	10
Group variables	None

Variable type: character

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
crash_date	0	1	22	22	0	189087	0

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
traffic_control_device	0	1	5	24	0	19	0
weather_condition	0	1	4	24	0	12	0
lighting_condition	0	1	4	22	0	6	0
first_crash_type	0	1	5	28	0	18	0
trafficway_type	0	1	4	31	0	20	0
alignment	0	1	12	21	0	6	0
roadway_surface_cond	0	1	3	15	0	7	0
road_defect	0	1	5	17	0	7	0
crash_type	0	1	22	32	0	2	0
intersection_related_i	0	1	1	1	0	2	0
damage	0	1	11	13	0	3	0
prim_contributory_cause	0	1	6	80	0	40	0
most_severe_injury	0	1	5	24	0	5	0

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
num_units	0	1	2.06	0.40	1	2	2	2	11	
injuries_total	0	1	0.38	0.80	0	0	0	1	21	
injuries_fatal	0	1	0.00	0.05	0	0	0	0	3	
injuries_incapacitating	0	1	0.04	0.23	0	0	0	0	7	
injuries_non_incapacitating	0	1	0.22	0.61	0	0	0	0	21	
injuries_reported_not_evident	0	1	0.12	0.45	0	0	0	0	15	
injuries_no_indication	0	1	2.24	1.24	0	2	2	3	49	
crash_hour	0	1	13.37	5.60	0	9	14	17	23	
crash_day_of_week	0	1	4.14	1.97	1	2	4	6	7	
crash_month	0	1	6.77	3.43	1	4	7	10	12	

```
head(dataset)
```

```

      crash_date traffic_control_device weather_condition
1 07/29/2023 01:00:00 PM      TRAFFIC SIGNAL      CLEAR
2 08/13/2023 12:11:00 AM      TRAFFIC SIGNAL      CLEAR
3 12/09/2021 10:30:00 AM      TRAFFIC SIGNAL      CLEAR
4 08/09/2023 07:55:00 PM      TRAFFIC SIGNAL      CLEAR
5 08/19/2023 02:55:00 PM      TRAFFIC SIGNAL      CLEAR
6 09/06/2023 12:59:00 AM      NO CONTROLS      RAIN
      lighting_condition first_crash_type trafficway_type      alignment
1      DAYLIGHT      TURNING      NOT DIVIDED STRAIGHT AND LEVEL
```

2	DARKNESS, LIGHTED ROAD	TURNING	FOUR WAY STRAIGHT AND LEVEL
3	DAYLIGHT	REAR END	T-INTERSECTION STRAIGHT AND LEVEL
4	DAYLIGHT	ANGLE	FOUR WAY STRAIGHT AND LEVEL
5	DAYLIGHT	REAR END	T-INTERSECTION STRAIGHT AND LEVEL
6	DARKNESS, LIGHTED ROAD	FIXED OBJECT	NOT DIVIDED STRAIGHT AND LEVEL
	roadway_surface_cond	road_defect	crash_type
1	UNKNOWN	UNKNOWN	NO INJURY / DRIVE AWAY
2	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY
3	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY
4	DRY	NO DEFECTS	INJURY AND / OR TOW DUE TO CRASH
5	UNKNOWN	UNKNOWN	NO INJURY / DRIVE AWAY
6	WET	UNKNOWN	INJURY AND / OR TOW DUE TO CRASH
	intersection_related_i	damage	prim_contributory_cause
1	Y	\$501 - \$1,500	UNABLE TO DETERMINE
2	Y	OVER \$1,500	IMPROPER TURNING/NO SIGNAL
3	Y	\$501 - \$1,500	FOLLOWING TOO CLOSELY
4	Y	OVER \$1,500	UNABLE TO DETERMINE
5	Y	\$501 - \$1,500	DRIVING SKILLS/KNOWLEDGE/EXPERIENCE
6	N	\$501 - \$1,500	UNABLE TO DETERMINE
	num_units	most_severe_injury	injuries_total injuries_fatal
1	2	NO INDICATION OF INJURY	0 0
2	2	NO INDICATION OF INJURY	0 0
3	3	NO INDICATION OF INJURY	0 0
4	2	NONINCAPACITATING INJURY	5 0
5	2	NO INDICATION OF INJURY	0 0
6	1	NONINCAPACITATING INJURY	2 0
	injuries_incapacitating	injuries_non_incapacitating	
1	0	0	
2	0	0	
3	0	0	
4	0	5	
5	0	0	
6	0	2	
	injuries_reported_not_evident	injuries_no_indication	crash_hour
1	0	3	13
2	0	2	0
3	0	3	10
4	0	0	19
5	0	3	14
6	0	0	0
	crash_day_of_week	crash_month	
1	7	7	
2	1	8	

3	5	12
4	4	8
5	7	8
6	4	9

3.1 Duplikate entfernen

Mithilfe der Funktion `distinct()` werden Duplikate aus dem Datensatz entfernt. Dadurch wird sichergestellt, dass einzelne Unfälle nicht mehrfach in die Auswertung eingehen und die berechneten Häufigkeiten nicht verzerrt werden.

```
#|label: Duplikate-findern
dataset.clean <- dataset %>%
  distinct()
```

3.2 Feature Engineering

Die Zeitvariable `crash_date` wird in ein Date-Time-Objekt überführt und anschließend genutzt, um Stunden, Wochentag, Monat und Jahr des Unfalls abzuleiten. Die im Datensatz vorhandenen Variablen `crash_hour`, `crash_day_of_week` und `crash_month` werden nicht verwendet, da ihre numerische Codierung interpretationsabhängig ist. Durch die Ableitung aus dem Zeitstempel wird eine konsistente zeitliche Referenz sichergestellt.

Zusätzlich wird eine neue Variable `season` erzeugt, welche die Monate zu Jahreszeiten zusammenfasst. Dies dient der späteren Untersuchung saisonaler Muster.

Die Variable `most_severe_injury` wird zu einer binären Zielgröße `has_injury` umkodiert, die angibt, ob bei einem Unfall mindestens eine Verletzung aufgetreten ist. Diese Reduktion ermöglicht einen klaren und vergleichbaren Maßstab für die relative Unfallschwere.

```
#|label: Feature-Engineering
dataset.clean <- dataset.clean %>%
  mutate(
    crash_timestamp = mdy_hms(crash_date),

    crash_hour_num = hour(crash_timestamp),
    crash_wday_label = wday(crash_timestamp, label = TRUE, abbr = FALSE, week_start = 1),
    crash_month_label = month(crash_timestamp, label = TRUE, abbr = FALSE),
    crash_year_num = year(crash_timestamp),

    season = case_when(
      crash_month_label %in% c("Dezember", "Januar", "Februar") ~ "Winter",
```

```

    crash_month_label %in% c("März", "April", "Mai") ~ "Spring",
    crash_month_label %in% c("Juni", "Juli", "August") ~ "Summer",
    crash_month_label %in% c("September", "Oktober", "November") ~ "Autumn"
  ),

  has_injury = if_else(most_severe_injury == "NO INDICATION OF INJURY", FALSE, TRUE)
)

```

3.3 Selektieren der relevanten Attribute

Für die weiteren Analysen wird der Datensatz auf jene Variablen reduziert, die einen direkten Bezug zur Fragestellung haben. Dazu zählen zeitliche Merkmale, infrastrukturelle Eigenschaften, Umgebungsbedingungen sowie zentrale Unfallcharakteristika. Durch diese Selektion wird die Komplexität des Datensatzes verringert und die Übersichtlichkeit für die folgenden Auswertungen erhöht.

Tabelle 4: Übersicht der verwendeten Attribute und deren Relevanz für die Analyse

Kategorie	Attribut	Beschreibung
Zeitliche Faktoren	crash_hour_num	Stunde des Unfalls (tageszeitliche Muster)
	crash_wday_label	Wochentag des Unfalls (Werktag vs. Wochenende)
	crash_month_label	Monat des Unfalls (saisonale Muster)
Straßen- und Infrastruktur	trafficway_type	Art der Straße (z.B. Autobahn, Landstraße)
	alignment	Straßenverlauf (gerade, Kurve)
	road_defect	Vorhandene Straßenschäden
	intersection_related_i	Kreuzungsbezug (ja/nein)
Umgebungs- und Sichtbedingungen	traffic_control_device	Art der Verkehrsregelung (Ampel, Schild)
	weather_condition	Wetterlage zum Unfallzeitpunkt
	lighting_condition	Lichtverhältnisse (Tageslicht, Dunkelheit)
	roadway_surface_cond	Fahrbahnzustand (trocken, nass, Eis)
Unfallcharakteristika	first_crash_type	Initiale Aufprallart (frontal, Heck, etc.)
	crash_type	Gesamttyp des Unfalls

Kategorie	Attribut	Beschreibung
	prim_contributory_cause	Textuell erfasste Hauptursache des Unfalls

```
dataset.clean <- dataset.clean %>%
  select(
    # Zeitliche Faktoren
    crash_year_num, crash_hour_num, crash_wday_label, crash_month_label,
    # Straßen- und Infrastruktur
    trafficway_type, alignment, roadway_surface_cond, road_defect, intersection_related_i,
    # Umgebungs- und Sichtbedingungen
    weather_condition, lighting_condition, traffic_control_device,
    # Unfallcharakteristika
    first_crash_type, crash_type, prim_contributory_cause, has_injury
  )
```

3.4 Datenwerte bereinigen

Mehrere kategoriale Variablen enthalten explizite Platzhalter wie UNKNOWN, UNABLE TO DETERMINE oder NOT APPLICABLE. Diese Einträge stellen keine inhaltlich interpretierbaren Ausprägungen dar und werden daher einheitlich zu NA umkodiert. Auf diese Weise können sie in der Analyse gezielt ausgeschlossen werden, um nicht die Verteilung der gültigen Kategorien zu verzerren.

```
dataset.clean <- dataset.clean %>%
  mutate(
    prim_contributory_cause = na_if(prim_contributory_cause, "UNABLE TO DETERMINE"),
    prim_contributory_cause = na_if(prim_contributory_cause, "NOT APPLICABLE"),
    weather_condition = na_if(weather_condition, "UNKNOWN"),
    road_defect = na_if(road_defect, "UNKNOWN"),
    lighting_condition = na_if(lighting_condition, "UNKNOWN"),
    roadway_surface_cond = na_if(roadway_surface_cond, "UNKNOWN"),
    traffic_control_device = na_if(traffic_control_device, "UNKNOWN")
  )
```

3.5 Gruppieren von Werten

Einige Variablen weisen eine sehr feingranulare oder uneinheitliche Kategorisierung auf. Um interpretierbare Ergebnisse zu ermöglichen, werden diese Werte zusammengefasst.

So wird der ursprüngliche Straßentyp (`trafficway_type`) zu einer vereinfachten Klassifikation aggregiert, die grundlegende Unterschiede wie getrennte Fahrbahnen, Kreuzungen oder Einbahnstraßen abbildet.

Analog dazu wird die Hauptunfallursache (`prim_contributory_cause`) in übergeordnete Ursachengruppen zusammengeführt, etwa Fahrfehler, Ablenkung, Alkohol- oder Drogeneinfluss sowie äußere Faktoren. Diese Gruppierung reduziert die Vielzahl einzelner Ausprägungen und ermöglicht aussagekräftige Vergleiche zwischen den Gruppen.

```
dataset.clean <- dataset.clean %>%
  mutate(
    # Wir erstellen eine vereinfachte Kategorie
    trafficway_type_simple = case_when(
      # 1. Alles was "Divided" ist (egal ob mit Mauer oder ohne)
      str_detect(trafficway_type, "DIVIDED") ~ "Divided Road",

      # 2. Einbahnstraßen
      trafficway_type == "ONE-WAY" ~ "One-Way",

      # 3. Normale Straßen (Nicht getrennt)
      trafficway_type %in% c("NOT DIVIDED", "TWO-WAY", "CENTER TURN LANE") ~ "Two-Way (Not D",

      # 4. Kreuzungen/ (alle Typen)
      trafficway_type %in% c("FOUR WAY",
                           "T-INTERSECTION",
                           "Y-INTERSECTION",
                           "L-INTERSECTION",
                           "FIVE POINT, OR MORE",
                           "ROUNDABOUT",
                           "UNKNOWN INTERSECTION TYPE") ~ "Intersection",

      # 5. Spezialfälle (alles andere z.B. Parking_lot, ramp, driveway, alley, unkonw/not rep
      TRUE ~ "Other"
    )
  ) %>%
  select(-trafficway_type) %>%

  mutate(
    cause_group = case_when(
      # --- 1. WETTER ---
      prim_contributory_cause == "WEATHER" ~ "Weather",

      # --- 2. Andere Externe Faktoren (Tiere, Straße, Sicht) ---
      prim_contributory_cause %in% c("ANIMAL",
```

```

"ROAD ENGINEERING/SURFACE/MARKING DEFECTS",
"VISION OBSCURED (SIGNS, TREE LIMBS, BUILDINGS, ETC.)",
"EVASIVE ACTION DUE TO ANIMAL, OBJECT, NONMOTORIST") ~ "

# --- 3. Ablenkung ---
str_detect(prim_contributory_cause, "DISTRACTION|TEXTING|CELL PHONE") ~ "Distracted Dr

# --- 4. Substanzen (Alkohol/Drogen) ---
str_detect(prim_contributory_cause, "ALCOHOL|DRINKING|DRUGS|HAD BEEN DRINKING") ~ "Imp

# --- 5. Raser / Aggressiv ---
str_detect(prim_contributory_cause, "SPEED|RECKLESS|AGGRESSIVE") ~ "Speeding/Aggressive

# --- 6. Regelverstöße (Ampel/Schilder) ---
str_detect(prim_contributory_cause, "YIELD|SIGNAL|STOP SIGN|RED LIGHT|DISREGARDING") ~

# --- 7. Klassische Fahrfehler ---
prim_contributory_cause %in% c("FOLLOWING TOO CLOSELY", "IMPROPER TURNING/NO SIGNAL",
                              "IMPROPER BACKING", "IMPROPER LANE USAGE",
                              "IMPROPER OVERTAKING/PASSING", "FAILING TO YIELD RIGHT-OF-WAY")

# --- 8. NA bleibt NA ---
is.na(prim_contributory_cause) ~ NA_character_,

# --- 9. Rest ---
TRUE ~ "Other Cause"
)
) %>%
select(-prim_contributory_cause)

```

3.6 Y/N-Spalten zu logischen Variablen transformieren

Die Variable `intersection_related_i` liegt im Datensatz als Zeichenkette mit den Werten Y und N vor. Diese Kodierung wird in eine logische Variable (TRUE / FALSE) überführt, um eine konsistente Weiterverarbeitung und Auswertung zu ermöglichen.

```

dataset.clean <- dataset.clean %>%
  mutate(
    intersection_related_i = if_else(intersection_related_i == "Y", TRUE, FALSE)
  )

```

4 Aggregation und Visualisierung der Daten

In diesem Kapitel werden die aufbereiteten Daten aggregiert und visuell ausgewertet, um die formulierte Fragestellung empirisch zu untersuchen. Durch geeignete Gruppierungen werden zentrale Muster im Unfallgeschehen sichtbar, die auf der Ebene der Rohdaten nicht unmittelbar erkennbar sind. Die Visualisierungen dienen dabei nicht nur der Veranschaulichung, sondern auch als analytisches Werkzeug, um Unterschiede zwischen Unfallhäufigkeit und relativer Unfallschwere systematisch herauszuarbeiten. Der Fokus liegt auf der Analyse zeitlicher, infrastruktureller und umgebungsbezogener Faktoren und deren Zusammenhang mit der Wahrscheinlichkeit von Personenschäden.

4.1 Untersuchung von zeitlichen Aspekten

Hier prüfen wir wie Verkehrsunfälle mit dem Wochentag, Jahreszeit oder der Uhrzeit zusammenhängen.

4.1.1 Unfallhäufigkeit

Für den ersten Überblick dient eine Heatmap zur Unfallhäufigkeit mit marginalen Histogrammen, um zeitliche Muster zu identifizieren.

```
# Histogramm Mitte (Heatmap)
dataset.timeAnalyse.plot1.heatmap_data <- dataset.clean %>%
  filter(!is.na(crash_wday_label), !is.na(crash_hour_num)) %>%
  count(crash_wday_label, crash_hour_num)

dataset.timeAnalyse.plot1.plot_main <- ggplot(dataset.timeAnalyse.plot1.heatmap_data, aes(x = crash_hour_num, y = crash_wday_label)) +
  geom_tile(color = "#fff") +
  scale_fill_viridis_c(option = "magma", direction = -1) +
  scale_x_continuous(breaks = seq(0, 23, 2)) +

  geom_hline(yintercept = 5.5, color = "#fff", linewidth = 6, linetype = "solid") +
  geom_hline(yintercept = 5.5, color = "#000", linewidth = 0.5, linetype = "dashed") +

  labs(x = "Uhrzeit", y = "Wochentag") +
  theme_minimal() +
  theme(legend.position = "bottom")

# Histogramm oben (Uhrzeiten)
dataset.timeAnalyse.plot1.plot_top <- ggplot(dataset.clean, aes(x = crash_hour_num)) +
  geom_bar(fill = "gray40") +
```



```

scale_x_continuous(breaks = seq(0, 23, 2), expand = c(0,0)) +
theme_void()

# Histogramm rechts (Wochentage)
dataset.timeAnalyse.plot1.plot_right <- ggplot(dataset.clean, aes(x = crash_wday_label)) +
  geom_bar(fill = "gray40") +
  coord_flip() + # Drehen!
  scale_x_discrete(expand = c(0,0)) +
  theme_void()

dataset.timeAnalyse.plot1.plot_top + plot_spacer() + dataset.timeAnalyse.plot1.plot_main + dataset.timeAnalyse.plot1.plot_right +
  plot_layout(
    heights = c(1, 5),
    widths = c(5, 1)
  ) +
  plot_annotation(
    title = "Unfallhäufigkeit an Wochentagen und Uhrzeiten",
    #subtitle = "Kombination aus detaillierten Zeitverlauf (Heatmap) und aggregierten Gesamtverläufen",
    theme = theme(plot.title = element_text(face = "bold"))
  )

```

Unfallhäufigkeit an Wochentagen und Uhrzeiten




Abbildung 1: Unfallhäufigkeit nach Wochentagen und Uhrzeiten, dargestellt als Heatmap mit marginalen Histogrammen

Auf den ersten Blick zeigt sich eine deutliche Konzentration der Unfälle am späten Nachmittag. Das obere Histogramm bestätigt, dass der Zeitraum zwischen 15:00 und 17:00 Uhr das globale Maximum im Tagesverlauf darstellt. Eine mögliche Erklärung hierfür ist, dass es sich um eine typische Feierabendzeit handelt, in der das Verkehrsaufkommen besonders hoch ist. In den Nachtstunden zwischen 00:00 und 05:00 Uhr ist das Unfallaufkommen hingegen am geringsten, was plausibel mit der insgesamt niedrigeren Verkehrsdichte in diesem Zeitraum erklärbar ist.

An Werktagen (Montag bis Freitag) folgt das Unfallgeschehen dem klassischen Rhythmus des Berufsverkehrs. Es zeigt sich eine deutliche Häufung am Nachmittag, wobei der Freitag zwischen 15:00 und 17:00 Uhr als klarer Spitzenreiter („Hotspot“) hervorsticht. Auch im rechten Randdiagramm wird deutlich, dass der Freitag insgesamt der unfallreichste Tag der Woche ist.

Interessant ist der signifikante Wandel im Unfallgeschehen zwischen dem Wochenende und den Werktagen (siehe gestrichelte Trennlinie). Das Wochenende löst das klare Muster der Stoßzeiten auf: Tagsüber sind die Unfälle breiter über Mittag und Nachmittag verteilt, ohne die extremen Spitzen der Werktage. Nachts und in den frühen Morgenstunden (0:00 bis 4:00 Uhr) zeigt sich hingegen ein gegensätzliches Muster: Während dieser Zeitraum an Werktagen nur eine geringe Unfalloffenheit aufweist, häufen sich am Wochenende in diesem Zeitraum die Unfälle deutlich. Dies deutet darauf hin, dass nächtliche Unfälle am Wochenende, vermutlich im Zusammenhang mit Freizeit- und Ausgangsverkehr, im Vergleich zu Werktagen deutlich häufiger auftreten.

4.1.2 Alkoholeinfluss und Unfallschwere

Die daraus abgeleitete Hypothese, dass die erhöhte Unfallschwere in den Nachtstunden mit Freizeit- und Ausgehverkehr zusammenhängt, wird im Folgenden anhand der zeitlichen Verteilung alkoholbedingter Unfälle näher untersucht.

```
dataset.timeAnalyse.plot2.alcohol_trend <- dataset.clean %>%
  filter(!is.na(crash_hour_num)) %>%
  mutate(is_alcohol = grepl("ALCOHOL|INTOXICATED", cause_group, ignore.case = TRUE)) %>%
  filter(is_alcohol == TRUE) %>%
  count(crash_hour_num)

ggplot(dataset.timeAnalyse.plot2.alcohol_trend, aes(x = crash_hour_num, y = n)) +
  geom_line(color = "#b00b1e", linewidth = 1.2) +
  scale_x_continuous(breaks = seq(0, 23, 2)) +
  labs(
    #subtitle = "'Party-Hypothese'",
    title = "Anzahl der alkoholbedingten Unfälle nach Uhrzeit",
    x = "Uhrzeit",
    y = "Anzahl Alkohol-Unfälle"
```

```
) +  
theme_minimal()
```




Abbildung 2: Zeitlicher Verlauf alkoholbedingter Verkehrsunfälle im Tagesverlauf

Die Kurve der alkoholbedingten Unfälle zeigt eine ausgeprägte Asymmetrie. Während Alkohol im morgendlichen Berufsverkehr (ca. 6:00 bis 10:00 Uhr) kaum eine Rolle spielt, steigt die Anzahl alkoholbedingter Unfälle ab den Abendstunden (ca. 20:00 Uhr) deutlich an.

Zusammenhang: Vergleicht man den zeitlichen Verlauf der alkoholbedingten Unfälle mit dem Diagramm der relativen Unfallschwere, zeigt sich eine starke zeitliche Übereinstimmung. Die Stunden mit der höchsten Anzahl an Personenschäden fallen mit den Zeiträumen zusammen, in denen alkoholbedingte Unfälle besonders häufig auftreten.

Diese Beobachtung legt nahe, dass die erhöhte Unfallschwere in den Nachtstunden weniger durch das Verkehrsaufkommen oder die Dunkelheit allein erklärbar ist, sondern maßgeblich mit riskantem Fahrverhalten zusammenhängt. Insbesondere Alkohol im Zusammenhang mit Freizeit- und Ausgangsverkehr scheint zur Diskrepanz zwischen geringer Unfallhäufigkeit und hoher Verletztenquote in der Nacht beizutragen.

4.1.3 Unfallschwere

Ergänzend zur Betrachtung der Unfallhäufigkeit wird im Folgenden die Unfallschwere analysiert. Hier wird dargestellt, wie hoch der Anteil an Personenschäden (rot) im Vergleich zu reinen Sachschäden (grau) ist.

Die folgenden Grafiken sind in Reitern organisiert und zeigen die Verteilung der Unfallschwere über den Monats-, Wochentags- und Stundenzyklus. Grundlage der Auswertung sind Unfalldaten aus dem Zeitraum von 2013 bis 2025.

4.1.3.1 Monats-Zyklus

Zur Betrachtung der saisonalen Komponente dient das folgende Kreisdiagramm. Ein Blick auf die Monate zeigt, ob es im Winter (Glatteis/Dunkelheit) oder Sommer (Ferienverkehr) häufiger zu einem Unfall kommt.

```
dataset.timeAnalyse.plot3.data_month <- dataset.clean %>%
  filter(!is.na(crash_month_label), !is.na(has_injury)) %>%
  count(crash_month_label, has_injury) %>%
  mutate(
    prozent = n / sum(n),
    label_text = ifelse(has_injury, paste0(round(prozent * 100, 1), "%"), "")
  )

# 2. PLOT
dataset.timeAnalyse.plot3.plot_month <- ggplot(dataset.timeAnalyse.plot3.data_month, aes(x =
  geom_col(width = 1, color = "white", linewidth = 0.1) +
  coord_polar(theta = "x", start = -pi/12) +
  scale_fill_manual(values = c("#c5c5c5", "#b00b1e"),
    labels = c("Nur Sachschaden", "Mit Verletzten")) +
  geom_text(aes(label = label_text),
    color = "#b00b1e",
    fontface = "bold",
    size = 4,
    nudge_y = 5000) +
  labs(title = "Monats-Zyklus (Januar bis Dezember)", x = NULL, y = NULL) +
  theme_minimal() +
  theme(
    axis.text.y = element_blank(),
    axis.ticks = element_blank(),
    panel.grid = element_line(color = "#eeeeee"),
    legend.position = "bottom",
    axis.text.x = element_text(size = 11, face = "bold", color = "#555555"),
```

```

plot.title = element_text(hjust = 0.5, face = "bold"),
plot.subtitle = element_text(hjust = 0.5)
)

```

```
dataset.timeAnalyse.plot3.plot_month
```

Monats-Zyklus (Januar bis Dezember)




Abbildung 3: Unfallhäufigkeit und Anteil von Unfällen mit Personenschaden im Jahresverlauf

Die Analyse des saisonalen Verlaufs (Monats-Zyklus) offenbart eine deutliche Diskrepanz zwischen Unfallhäufigkeit und Unfallschwere.

Während die absolute Anzahl der Unfälle (dargestellt durch die Länge der Segmente) zum Jahresende in den Monaten Oktober bis Dezember ihr Maximum erreicht, verhält sich die Unfallschwere (Anteil der Personenschäden) gegenläufig.

Erstaunlicherweise ist der relative Anteil an Verletzten im Spätsommer und Frühherbst (Juli bis September) am höchsten. Dies widerspricht auf den ersten Blick der Intuition, dass die "dunkle Jahreszeit" am gefährlichsten ist. Die Daten legen nahe, dass schlechte Witterung im Herbst zwar zu mehr Unfällen führt, diese aber oft glimpflicher ausgehen (Blebschäden durch z.B. Auffahrunfälle). Im Gegensatz dazu ist es möglich, dass die besseren Straßenverhältnisse im Sommer höhere Geschwindigkeiten und damit folgenschwerere Kollisionen begünstigen.

Das globale Minimum des Unfallgeschehens – sowohl nach Anzahl als auch nach Schwere – findet sich in den Monaten Februar bis April.

4.1.3.2 Wochen-Zyklus

Hier wird der Verlauf der Unfallhäufigkeit und der Schwere über die Wochentage verteilt dargestellt.

```
dataset.timeAnalyse.plot3.data_week <- dataset.clean %>%
  filter(!is.na(crash_wday_label), !is.na(has_injury)) %>%
  count(crash_wday_label, has_injury) %>%
  group_by(crash_wday_label) %>%
  mutate(
    prozent = n / sum(n),
    label_text = ifelse(has_injury, paste0(round(prozent * 100, 1), "%"), "")
  ) %>%
  ungroup()

dataset.timeAnalyse.plot3.plot_week <- ggplot(dataset.timeAnalyse.plot3.data_week, aes(x = crash_wday_label, y = count)) +
  geom_col(width = 1, color = "white", linewidth = 0.2) +
  coord_polar(theta = "x", start = -pi/7) +
  scale_fill_manual(values = c("#c5c5c5", "#b00b1e"),
                    labels = c("Nur Sachschaden", "Mit Verletzten")) +
  geom_text(aes(label = label_text,
                color = "#b00b1e",
                fontface = "bold",
                size = 4,
                nudge_y = 5000)) +
  labs(title = "Wochen-Zyklus (Montag bis Sonntag)", x = NULL, y = NULL) +
  theme_minimal() +
  theme(
    axis.text.y = element_blank(),
    axis.ticks = element_blank(),
    panel.grid = element_line(color = "#eeeeee"),
    legend.position = "bottom",
    axis.text.x = element_text(size = 11, face = "bold", color = "#555555"),
    plot.title = element_text(hjust = 0.5, face = "bold"),
    plot.subtitle = element_text(hjust = 0.5)
  )

dataset.timeAnalyse.plot3.plot_week
```

Wochen-Zyklus (Montag bis Sonntag)




Abbildung 4: Unfallhäufigkeit und Anteil von Unfällen mit Personenschaden im Wochenverlauf

Das Wochenend-Phänomen, das bereits in der Heatmap (Abb. 1) sichtbar ist, zeigt sich auch hier deutlich. Der Freitag sticht auch hier als unfallreichster Tag hervor (längstes Segment), weist aber mit 24,6% paradoxerweise die geringste Verletztenquote der Woche auf. Eine mögliche Erklärung ist der typische Stop-and-Go-Verkehr zum Wochenende, der durch geringere Geschwindigkeiten die Aufprallenergie bei Kollisionen reduziert. Im Kontrast dazu steht der Sonntag: Obwohl hier absolut gesehen am wenigsten Unfälle auftreten, ist das relative Risiko für Personenschäden mit 28,6% am höchsten. Dies deutet auf Freizeitverkehr hin, bei dem freiere Straßen zu höheren Geschwindigkeiten führen können, was im Falle einer Kollision gravierendere Folgen hat.

4.1.3.3 Tages-Zyklus

Aus Gründen der Übersichtlichkeit und zur detaillierten Analyse wird der Tageszyklus (0–23 Uhr) in zwei komplementäre Darstellungen unterteilt: eine Darstellung analog zu Monats- und Wochenzyklus sowie eine zweite, die den Fokus auf das tatsächliche Unfallrisiko legt.

```
dataset.timeAnalyse.plot3.data_hour <- dataset.clean %>%
  filter(!is.na(crash_hour_num), !is.na(has_injury)) %>%
  count(crash_hour_num, has_injury) %>%
  group_by(crash_hour_num) %>%
  mutate(
    prozent = n / sum(n),
```

```

    label_text = ifelse(has_injury, paste0(round(prozent * 100, 0), "%"), "")
  ) %>%
  ungroup()

dataset.timeAnalyse.plot3.plot_hour_total <- ggplot(dataset.timeAnalyse.plot3.data_hour, aes(
  geom_col(width = 1, color = "white", linewidth = 0.1) +
  coord_polar(theta = "x", start = 0) +
  scale_fill_manual(values = c("#c5c5c5", "#b00b1e"),
                    labels = c("Nur Sachschaden", "Mit Verletzten"))) +
  scale_x_discrete(breaks = c(0, 2, 4, 6, 8, 10, 12, 14, 16, 18, 20, 22)) +
  labs(title = "Total", subtitle = "Gesamtanzahl pro Stunde", x = NULL, y = NULL) +
  theme_minimal() +
  theme(
    axis.text.y = element_blank(),
    axis.ticks = element_blank(),
    panel.grid = element_line(color = "#eeeeee"),
    legend.position = "bottom",
    axis.text.x = element_text(size = 11, face = "bold", color = "#555555"),
    plot.title = element_text(hjust = 0.5, face = "bold"),
    plot.subtitle = element_text(hjust = 0.5)
  )

dataset.timeAnalyse.plot3.plot_hour_detail <- ggplot(dataset.timeAnalyse.plot3.data_hour, aes(
  geom_col(position = "fill", width = 1, color = "white", linewidth = 0.1) +
  coord_polar(theta = "x", start = 0) +
  scale_fill_manual(values = c("#c5c5c5", "#b00b1e"),
                    labels = c("Nur Sachschaden", "Mit Verletzten"))) +
  scale_x_discrete(breaks = c(0, 2, 4, 6, 8, 10, 12, 14, 16, 18, 20, 22)) +
  geom_text(data = filter(dataset.timeAnalyse.plot3.data_hour, has_injury == TRUE),
    aes(y = prozent, label = label_text),
    color = "#b00b1e",
    fontface = "bold",
    size = 3,
    nudge_y = 0.5) +
  labs(title = "Detail", subtitle = "Anteil Personen und Sachschaden auf Gesamtes pro Stunde") +
  theme_minimal() +
  theme(
    axis.text.y = element_blank(),
    axis.ticks = element_blank(),
    panel.grid = element_line(color = "#eeeeee"),

```



```

legend.position = "bottom",
axis.text.x = element_text(size = 11, face = "bold", color = "#555555"),
plot.title = element_text(hjust = 0.5, face = "bold"),
plot.subtitle = element_text(hjust = 0.5)
)

dataset.timeAnalyse.plot3.plot_hour_total + dataset.timeAnalyse.plot3.plot_hour_detail +
  plot_layout(guides = "collect") +
  plot_annotation(
    title = "Tages-Zyklus (0-23h)",
    theme = theme(plot.title = element_text(size = 16, face = "bold")),
  ) &
  theme(legend.position = "bottom")

```

Tages-Zyklus (0-23h)




Abbildung 5: Unfallhäufigkeit und Anteil von Unfällen mit Personenschaden im Tagesverlauf

Linke Grafik - Absolute Häufigkeit (“Total”): Dieses Diagramm visualisiert das absolute Unfallaufkommen. Die Länge der Segmente (Radius) entspricht der Gesamtanzahl der Unfälle pro Stunde.

Hier dominiert klar der Rhythmus des Berufsverkehrs: Die Segmente ragen tagsüber, insbesondere zwischen 15:00 und 18:00 Uhr, weit nach außen.

Die Unfallfolgen scheinen hierbei fast ausschließlich aus Sachschäden (grau) zu bestehen; der rote Kern (Personenschäden) wirkt im Verhältnis zur Gesamtmasse klein. Detaillierter sichtbar wird dies in der rechten Grafik.

Rechte Grafik- Relative Unfallschwere (“Detail”): Um das tatsächliche Risiko isoliert vom Verkehrsaufkommen zu betrachten, normiert diese Grafik jede Stunde auf 100%.

Hier zeigt sich ein völlig anderes Bild: Während tagsüber (z. B. 14:00 Uhr) der Anteil an Personenschäden auf ein Minimum von 24% sinkt, weitet sich der rote Kern in den Nachtstunden stark aus.

Das relative Risiko erreicht zwischen 1:00 und 3:00 Uhr nachts seinen Höhepunkt: Hier enden rund 33% – also jeder dritte Unfall – mit Verletzungen.

Fazit: Die Kombination beider Grafiken verdeutlicht das zugrunde liegende Paradoxon: Tagsüber ereignen sich zwar die meisten Unfälle, diese verlaufen jedoch überwiegend glimpflich (z.B. Blechschaden bei einem Auffahrunfall im dichten Verkehr). Nachts treten die wenigsten Unfälle auf, diese sind jedoch mit einem wesentlich höheren Anteil an Personenschäden verbunden.

4.1.4 Fazit: Zeitliche Aspekte

Unfallhäufigkeit und Unfallschwere verhalten sich antizyklisch. Während dichter Verkehr und winterliche Witterung zwar vor allem zu einer hohen Anzahl an Unfällen mit überwiegend geringen Schäden führen, treten die folgenswersten Unfälle häufiger bei geringer Verkehrsdichte nachts und am Wochenende auf. Die Ergebnisse deuten darauf hin, dass dabei weniger die äußeren Rahmenbedingungen als vielmehr riskantes Fahrverhalten, insbesondere im Zusammenhang mit Alkoholkonsum, eine zentrale Rolle für schwere Personenschäden spielt.

4.2 Untersuchung der Verkehrssituation

Nachdem die zeitlichen Aspekte untersucht wurden, wird nun der Fokus auf die infrastrukturellen und situativen Rahmenbedingungen der Unfälle gerichtet. Konkret wird analysiert, ob die Art der Straße (Kreuzung, geteilte Fahrbahn, usw.), der Unfalltyp (Abbiegen, Auffahren, usw.) und die vorhandene Verkehrsregelung (Ampel, Stop-Schild, keine Regelung) einen Einfluss auf die Unfallschwere haben. Das Ziel ist, zu verstehen, welche Verkehrssituationen besonders risikoreich sind und ob bestimmte Infrastrukturtypen systematisch mit höheren Verletzungsraten einhergehen.

4.2.1 Begriffsklärung

Da der verwendete Datensatz aus dem US-amerikanischen Raum stammt, liegen zentrale Variablen in englischer Sprache vor. Zur besseren Verständlichkeit werden die wichtigsten Begriffe vorab kurz erläutert:

Straßentypen (`trafficway_type_simple`):

- *Two-Way, Not Divided*: Zweispurige Straße ohne bauliche Mitteltrennung, bei der der Gegenverkehr auf derselben Fahrbahn fließt
- *Divided Road*: Mehrspurige Straße mit baulicher Trennung zwischen den Fahrtrichtungen (z.B. durch Leitplanken oder Grünstreifen)
- *Intersections*: Kreuzungen, an denen sich mindestens zwei Verkehrsströme kreuzen
- *One-Way*: Einbahnstraße, auf der der Verkehr nur in eine Richtung fließt

Unfalltypen (`first_crash_type`):

- *Head On*: Frontalzusammenstoß zwischen zwei Fahrzeugen
- *Angle*: Seitlicher Aufprall, typischerweise an Kreuzungen bei kreuzenden Fahrbahnen
- *Turning*: Unfälle beim Abbiegevorgang
- *Rear End*: Auffahrunfall, bei dem ein Fahrzeug auf ein anderes auffährt
- *Pedestrian*: Kollision zwischen Fahrzeug und Fußgänger
- *Pedalcyclist*: Kollision zwischen Fahrzeug und Radfahrer
- *Fixed Object*: Kollision mit einem festen Objekt (z.B. Baum, Pfosten, Mauer)

Verkehrsregelungen (`traffic_control_device`):

- *Traffic Signal*: Ampelanlage zur Regelung des Verkehrsflusses
- *Stop Sign/Flasher*: Stop-Schild oder Blinklicht, das zum vollständigen Anhalten verpflichtet
- *No Controls*: Keine formale Verkehrsregelung vorhanden
- *Yield*: Vorfahrtgewähren Schild (Verkehrsteilnehmende sind wartepflichtig)
- *Pedestrian Crossing Sign*: Fußgängerüberweg (Zebrastreifen)

4.2.2 Straßentyp und Unfallschwere

Zunächst untersuchen wir den Zusammenhang zwischen dem Straßentyp und der Verletzungsrate. Dabei ist es wichtig zwischen der absoluten Unfallohaufigkeit (wie viele Unfälle passieren auf diesem Straßentyp?) und der relativen Unfallschwere (wie gefährlich ist ein Unfall, wenn er dort passiert) zu unterscheiden. Ein Straßentyp mit vielen Unfällen ist nicht zwangsläufig der gefährlichste, wenn diese Unfälle überwiegend glimpflich verlaufen.

4.2.2.1 Verletzungsrate (relativ)

```
dataset_verkehrsanalyse <- dataset.clean %>%
  filter(!is.na(trafficway_type_simple), !is.na(has_injury)) %>%
  group_by(trafficway_type_simple) %>%
  summarise(
    anzahl_total = n(),
    anzahl_verletzte = sum(has_injury),
    verletzungsrate = mean(has_injury) * 100
  ) %>%
  arrange(desc(verletzungsrate))

ggplot(dataset_verkehrsanalyse, aes(x = verletzungsrate, y = reorder(trafficway_type_simple,
  geom_col(fill = "#b00b1e") +
  labs(
    title = "Verletzungsrate nach Straßentyp",
    x = "Anteil der Unfälle mit Verletzten (%)",
    y = "Typen"
  ) +
  theme_minimal()
```




Abbildung 6: Anteil von Unfällen mit Personenschaden nach Straßentyp

Die Analyse zeigt deutliche Unterschiede in der Unfallschwere zwischen verschiedenen Straßen-

typen. Kreuzungen (*Intersections*) weisen mit 31,66 % die höchste Verletzungsrate auf - fast jeder dritte Unfall an einer Kreuzung endet mit Verletzten. Dies lässt sich wahrscheinlich durch die Komplexität der Verkehrssituation erklären: Kreuzende Verkehrsströme, Vorfahrtsregeln und Abbiegevorgänge erhöhen das Risiko für schwere Kollisionen, insbesondere bei seitlichem Aufprall.

Interessanterweise liegt die Verletzungsrate auf normalen zweispurigen Straßen (*Two-Way, Not Divided*) mit 27,85 % deutlich höher als auf baulich getrennten Fahrbahnen (*Divided Road*: 24.04 %). Dies könnte auf das Risiko von Frontalzusammenstößen bei fehlender Mittel-trennung zurückzuführen sein. Einbahnstraßen (*One-Way*) zeigen mit 19,50% die niedrigste Verletzungsrate, was vermutlich an der reduzierten Komplexität der Verkehrsführung liegt.

Bei der Interpretation ist jedoch zu beachten, dass die absolute Unfallhäufigkeit stark variiert: Während auf *Divided Roads* mit 122.673 Unfällen die meisten Kollisionen passieren, ereignen sich auf *Two-Way-Roads* mit nur 2.862 Unfällen vergleichsweise wenige. Die höhere Verletzungsrate bedeutet jedoch, dass ein einzelner Unfall auf einer *Two-Way-Road* mit höherer Wahrscheinlichkeit schwer verläuft als auf einer *Divided Road* - trotz der insgesamt geringeren absoluten Anzahl an Verletzten.

4.2.2.2 Absolute Unfallhäufigkeit

```
ggplot(dataset_verkehrsanalyse, aes(x = anzahl_verletzte, y = reorder(trafficway_type_simple,
  geom_col(fill = "grey70") +
  labs(
    title = "Absolute Häufigkeit der Verletzten nach Straßentyp",
    x = "Anzahl Verletzte",
    y = "Typen"
  ) +
  theme_minimal()
```




Abbildung 7: Absolute Anzahl verletzter Personen nach Straßentyp

Die absolute Anzahl verletzter Personen zeigt ein anderes Bild als die Verletzungsrate: Auf *Divided Roads* werden mit 29.491 die meisten verletzten Personen verzeichnet, obwohl die Verletzungsrate dort mit 24,04 % niedriger ist als bei *Intersections* (31,66 %) oder *Two-Way-Roads* (27,85 %). Dies verdeutlicht das Paradoxon zwischen relativem Risiko und absoluter Häufigkeit.

Während bei *Intersections* fast jeder dritte Unfall mit Verletzten endet, geschehen dort absolut deutlich weniger schwere Unfälle (19.795) als auf *Divided Roads*. *Two-Way-Roads* weisen mit nur 797 Verletzten die geringste absolute Belastung auf, trotz ihrer vergleichsweise hohen Verletzungsrate.

Um die vermuteten Ursachen für die unterschiedlichen Verletzungsraten näher zu untersuchen, wird im Folgenden analysiert, welche Unfalltypen auf welchen Straßentypen dominieren und ob sich dadurch die beobachteten Unterschiede in der Verletzungsrate erklären lassen.

4.2.3 Welche Unfalltypen sind mit hoher Unfallschwere verbunden?

Um die Vermutungen zu den Gründen der unterschiedlichen Gefährlichkeit zu überprüfen, wird der Zusammenhang zwischen Straßentyp und Unfalltyp grafisch dargestellt. Dabei wird festgelegt, auf welche Unfalltypen der Fokus gelegt wird. Für die Prüfung der Hypothesen sind insbesondere die Unfalltypen *Head On* (Frontalzusammenstoß), *Angle* (seitlicher Aufprall) und *Turning* (Abbiegen) relevant.

```
dataset.unfalltypen <- dataset.clean %>%
  filter(!is.na(trafficway_type_simple), !is.na(first_crash_type), !is.na(has_injury)) %>%
  group_by(trafficway_type_simple, first_crash_type) %>%
  summarise(
    anzahl = n(),
    verletzungsrage = mean(has_injury) * 100
  )
```

`summarise()` has grouped output by 'trafficway_type_simple'. You can override using the `.groups` argument.

```
top_unfalltypen <- dataset.unfalltypen %>%
  group_by(first_crash_type) %>%
  summarise (total_anzahl = sum(anzahl)) %>%
  arrange(desc(total_anzahl)) %>%
  #Entscheidung: Top 10 zu nehmen
  head(10) %>%
  pull(first_crash_type)
```

In den Top-10-Unfalltypen nach absoluter Häufigkeit sind alle drei für unsere Hypothese relevanten Typen (*Head On*, *Angle*, *Turning*) enthalten. Daher ist es ausreichend, die Top-10-Unfalltypen in der folgenden Heatmap zu betrachten.

```
dataset.unfalltypen.top10 <- dataset.unfalltypen %>%
  filter(first_crash_type %in% top_unfalltypen)

ggplot(dataset.unfalltypen.top10, aes(x = first_crash_type, y = trafficway_type_simple, fill = verletzungsrage)) +
  geom_tile(color = "white") +
  geom_text(aes(label = round(verletzungsrage, 1)), color = "black", size = 3) +
  scale_fill_gradient(low = "#f0f0f0", high = "#b00b1e", name = "Verletzungsrage (%)") +
  labs(
    title = "Verletzungsrage abhängig von Straßentyp und Unfalltyp",
    x = "Unfalltyp",
    y = "Straßentyp"
  ) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1) # Unfalltypen schräg
  )
```




Abbildung 8: Verletzungsrate (Anteil der Unfälle mit Personenschäden) nach Unfalltyp und Straßentyp

Die Vermutung, dass Kreuzungen aufgrund seitlicher Aufprälle (*Angle*) und Abbiegevorgänge (*Turning*) besonders gefährlich sind, wird teilweise bestätigt. *Angle*-Unfälle an Kreuzungen weisen mit 37 % eine erhöhte Verletzungsrate auf - allerdings zeigt sich überraschenderweise die höchste Rate bei *Two-Way*-Straßen mit 43,2 %. Dies deutet darauf hin, dass fehlende bauliche Trennung bei seitlichen Kollisionen noch gefährlicher sind als die Komplexität von Kreuzungen.

Deutlich bestätigt wird die Hypothese zu Frontalzusammenstößen. *Head On*-Unfälle auf *Two Way*-Straßen zeigen mit 40,8 % eine deutlich höhere Verletzungsrate als auf *Divided Roads* (39,2 %). Dies unterstreicht die Schutzwirkung baulicher Mitteltrennungen gegen die gefährlichen Kollisionsarten.

Weitere Erkenntnisse: Das auffälligste Muster der Heatmap ist die extrem hohe Verletzungsrate bei *Pedestrian* (89-93 %) und *Pedalcyclist* (70-78 %) über alle Straßentypen hinweg. Diese Unfalltypen enden nahezu immer mit Verletzten, unabhängig vom Straßentyp. Im Gegensatz dazu zeigen klassische Auto-gegen-Auto-Unfälle (*Rear End*) (13-18 %) oder Kollision mit einem festen Objekt (*Fixed Object*, 5-18 %) deutlich niedrigere Raten. Dies wirft die Frage auf, welche Verkehrsregelungen (Ampeln, Vorfahrtsregeln) diese Unfälle verhindern könnten. Konkret wird daher im nächsten Schritt untersucht, wie sich diese Unfalltypen auf verschiedene Verkehrsregelungen verteilen und in welchen Situationen bestimmte Regelungen mit geringeren Verletzungsraten einhergehen.

4.2.4 Wie Verkehrsregelungen die Unfallschwere verschiedener Unfalltypen beeinflussen

Um das konkret zu prüfen, wird der Zusammenhang zwischen Verkehrsregelung und Unfalltyp analysiert. Dabei ist zunächst zu klären, welche Verkehrsregelungen im Datensatz vertreten sind und welche davon für die weitere Analyse berücksichtigt werden sollen.

```
dataset.verkehrslage <- dataset.clean %>%
  filter(!is.na(first_crash_type), !is.na(traffic_control_device), !is.na(has_injury)) %>%
  group_by(first_crash_type, traffic_control_device) %>%
  summarise(
    anzahl = n(),
    verletzungsrate = mean(has_injury) * 100
  )
```

`summarise()` has grouped output by 'first_crash_type'. You can override using the `.groups` argument.

```
top_verkehrslage <- dataset.verkehrslage %>%
  group_by(traffic_control_device) %>%
  summarise (total_anzahl = sum(anzahl)) %>%
  arrange(desc(total_anzahl))
```

Nach Sichtung der vorhandenen Verkehrsregelungen wird deutlich, dass nicht alle Kategorien berücksichtigt werden können, da dies den Rahmen der Analyse sprengen würde. Die fünf häufigsten Verkehrsregeltypen decken jedoch den Großteil der Unfälle ab. Entsprechend wird die Analyse auf *Traffic Signal*, *Stop Sign/Flasher*, *No Control*, *Yield* und *Pedestrian Crossing Sign* beschränkt.

Hinsichtlich der Unfalltypen heben sich in der vorherigen Headmap insbesondere *Pedalcyclist*, *Pedestrian*, *Angle*, *Fixed Object* und *Head On* hervor, auf die sich die weitere Betrachtung konzentriert.

```
top_unfalltypen_top5 <- c("PEDESTRIAN", "PEDALCYCLIST", "ANGLE",
                          "HEAD ON", "FIXED OBJECT")

verkehrsregelungen <- c("TRAFFIC SIGNAL", "STOP SIGN/FLASHER", "NO CONTROLS", "YIELD", "PEDE")

dataset.verkehrslage.fokus <- dataset.verkehrslage %>%
  filter(
    first_crash_type %in% top_unfalltypen_top5,
    traffic_control_device %in% verkehrsregelungen
  )
```

```
ggplot(dataset.verkehrslage.fokus, aes(x = traffic_control_device, y = verletzungsrage, fill =
  geom_col(position = "dodge") + # "dodge" = nebeneinander
  labs(
    title = "Verletzungsrate nach Unfalltyp und Verkehrsregelung",
    x = "Unfalltyp",
    y = "Verletzungsrate (%)",
    fill = "Verkehrsregelung"
  ) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1)
  )
)
```




Abbildung 9: Verletzungsrate (Anteil der Unfälle mit Personenschäden) nach Unfalltyp und Verkehrsregelung

Im Anschluss an die Analyse von Straßentyp und Unfallart zeigt der Vergleich der Verkehrsregelungen, dass ungeschützte Verkehrsteilnehmende über alle Settings hinweg das höchste Risiko tragen: *Pedestrian* und *Pedalcyclist* weisen durchgängig sehr hohe Verletzungsraten auf (meist 75–95 %), unabhängig davon, ob eine Ampel, ein Stop-Zeichen oder eine andere Regelung vorhanden ist. Bei den motorisierten Unfalltypen (*Angle*, *Head On*, *Fixed Object*) reagiert die Verletzungsrate stärker auf die Art der Regelung: Bereiche ohne formale Kontrolle

(*No Controls*) liegen tendenziell höher, während klare Kontrollen (*Traffic Signal, Stop/Flasher*) mit niedrigeren Raten einhergehen; *Yield* bewegt sich dazwischen. Damit fügt sich diese Erkenntnis schlüssig in die vorigen Ergebnisse ein: Komplexe Konfliktsituationen wie Seiten- und Frontalzusammenstöße profitieren sichtbar von eindeutiger Regulierung, während die Schwere bei Fußgänger- und Radfahrunfällen strukturell hoch bleibt und durch die Regelungsart allein weniger stark gedämpft wird.

4.2.5 Straßenausrichtung und Unfallschwere

Nachdem die Analyse gezeigt hat, dass Straßentyp und Verkehrsregelung die Unfallschwere maßgeblich beeinflussen, stellt sich die Frage, ob auch die geometrische Beschaffenheit der Straße - also ihre Ausrichtung und Führung - einen systematischen Einfluss auf die Verletzungsrate hat. Die Variable `alignment` erfasst, ob ein Unfall auf einer geraden, ebenen Strecke, in einer Kurve oder an einer Steigung passiert ist.

Komplexere Streckenführung wie Kurven, insbesondere in Kombination mit Steigungen oder Bergkuppen, erfordern höhere Aufmerksamkeit und Fahrzeugkontrollen. Dementsprechend werden wahrscheinlich die Abschnitte mit höheren Verletzungsraten auftreten als gerade, ebene Strecken.

```
dataset.alignmentAnalysis.alignment_summary <- dataset.clean %>%
  filter(!is.na(alignment), !is.na(has_injury)) %>%
  group_by(alignment) %>%
  summarize(
    anzahl_unfaelle = n(),
    verletzungsrage = mean(has_injury) * 100
  ) %>%
  arrange(desc(verletzungsrage))
```

4.2.5.1 Absolute Unfallhäufigkeit

```
alignment_labels <- c(
  "STRAIGHT AND LEVEL" = "Gerade und eben",
  "STRAIGHT ON GRADE" = "Gerade mit Steigung",
  "CURVE, LEVEL" = "Kurve, eben",
  "STRAIGHT ON HILLCREST" = "Gerade auf Bergkuppe",
  "CURVE ON GRADE" = "Kurve mit Steigung",
  "CURVE ON HILLCREST" = "Kurve auf Bergkuppe"
)

dataset.alignmentAnalysis.plot_absolute <- ggplot(
```

```

dataset.alignmentAnalysis.alignment_summary,
aes(x = anzahl_unfaelle, y = reorder(alignment, anzahl_unfaelle))
) +
geom_col(fill = "grey70") +
scale_y_discrete(labels = alignment_labels) +
labs(
  title = "Absolute Unfallhäufigkeit nach Straßenausrichtung",
  x = "Anzahl Unfälle",
  y = "Straßenausrichtung"
) +
theme_minimal()

dataset.alignmentAnalysis.plot_absolute

```




Abbildung 10: Absolute Unfallhäufigkeit nach Straßenausrichtung

Die Verteilung der absoluten Unfallzahlen wird klar von geraden und ebenen Strecken dominiert, auf denen über 200.000 Unfälle registriert wurden. Kurven und Steigungen machen zusammen weniger als 5% aller Unfälle aus. Besonders auffällig ist die geringe Fallzahl bei Kurve mit Steigung(179 Unfälle) und Kurve auf Bergkuppe(53 Unfälle), was die statische Belastbarkeit der Kategorien einschränkt.

4.2.5.2 Relative Unfallschwere

```
dataset.alignmentAnalysis.plot_injuryRate <- ggplot(  
  dataset.alignmentAnalysis.alignment_summary,  
  aes(x = verletzungsrage, y = reorder(alignment, verletzungsrage))  
) +  
  geom_col(fill = "#b00b1e") +  
  scale_y_discrete(labels = alignment_labels) +  
  labs(  
    title = "Verletzungsrate nach Straßenausrichtung",  
    x = "Anteil Unfälle mit Verletzten (%)",  
    y = "Straßenausrichtung"  
  ) +  
  theme_minimal()  
  
dataset.alignmentAnalysis.plot_injuryRate
```




Abbildung 11: Verletzungsrate (Anteil der Unfälle mit Personenschäden) nach Straßenausrichtung

Die Grafik zur relativen Unfallschwere zeigt, dass gerade und ebene Strecken trotz ihrer hohen absoluten Unfallzahlen eine moderate Verletzungsrate von etwa 28% aufweisen. Die komplexesten Streckenkombinationen weisen die höchsten Verletzungsraten auf: Kurven auf Bergkuppen

führen mit ~37%, gefolgt von Kurven mit Steigung (~35%). Auch gerade Strecken auf Bergkuppen zeigen mit ~31% eine erhöhte Gefährlichkeit. Überraschend ist jedoch, dass ebene Kurven mit nur ~22% die niedrigste Verletzungsrate aller Kategorien aufweisen – niedriger sogar als gerade Strecken. Dies widerspricht teilweise der aufgestellten Hypothese und könnte darauf hindeuten, dass Kurven ohne zusätzliche Höhenunterschiede besser einsehbar sind und zu angepasstem Fahrverhalten führen. Die objektiv anspruchsvollsten Kategorien (Kurve mit Steigung, Kurve auf Bergkuppe) zeigen zwar hohe, aber aufgrund der sehr geringen Fallzahlen (179 bzw. 53 Unfälle) statistisch wenig belastbare Werte.

Interpretation der Ergebnisse

Die Hypothese, dass komplexere Streckenführungen grundsätzlich mit höherer Unfallschwere verbunden sind, wird durch die Daten nur teilweise bestätigt. Während Kurven in Kombination mit Höhenunterschieden (Bergkuppen, Steigungen) tatsächlich die höchsten Verletzungsraten aufweisen, zeigt sich bei ebenen Kurven überraschenderweise die niedrigste Rate aller Kategorien. Dies deutet darauf hin, dass nicht die Kurve an sich, sondern die Kombination aus horizontaler und vertikaler Streckenführung besonders kritisch ist. Das bereits mehrfach beobachtete Muster bestätigt sich erneut: Die meisten Unfälle ereignen sich auf geraden und ebenen Strecken, diese verlaufen jedoch im Durchschnitt weniger schwer als Unfälle auf anspruchsvolleren Streckenabschnitten. Die geometrische Komplexität – insbesondere die Kombination verschiedener Herausforderungen – hat somit einen messbaren Einfluss auf die Unfallschwere, allerdings differenzierter als ursprünglich vermutet.

4.2.6 Straßenschäden und Unfallschwere

Nachdem die Straßenführung analysiert wurde, stellt sich abschließend die Frage, ob auch der bauliche Zustand der Fahrbahn selbst die Unfallschwere beeinflusst. Die Variable `road_defect` erfasst, ob zum Unfallzeitpunkt Mängel wie abgenutzte Oberflächen, Spurrillen, Löcher oder Trümmer auf der Fahrbahn vorlagen.

Hypothese: Straßenschäden erschweren die Fahrzeugkontrolle und können zu abrupten Ausweichmanövern führen. Wir erwarten daher, dass Unfälle auf schadhaften Straßen mit höheren Verletzungsraten einhergehen als solche auf intakten Fahrbahnen.

```
dataset.roadDefectAnalysis.defect_summary <- dataset.clean %>%  
  filter(!is.na(road_defect), !is.na(has_injury)) %>%  
  group_by(road_defect) %>%  
  summarize(  
    anzahl_unfaelle = n(),  
    verletzungsrage = mean(has_injury) * 100  
  ) %>%  
  arrange(desc(verletzungsrage))
```

4.2.6.1 Absolute Unfallhäufigkeit

```
road_defect_labels <- c(
  "NO DEFECTS" = "Keine Defekte",
  "WORN SURFACE" = "Abgenutzte Oberfläche",
  "OTHER" = "Sonstige",
  "RUT, HOLES" = "Spurrillen/Löcher",
  "SHOULDER DEFECT" = "Seitenstreifenschaden",
  "DEBRIS ON ROADWAY" = "Trümmer auf Fahrbahn"
)

dataset.roadDefectAnalysis.plot_absolute <- ggplot(
  dataset.roadDefectAnalysis.defect_summary,
  aes(x = anzahl_unfaelle, y = reorder(road_defect, anzahl_unfaelle))
) +
geom_col(fill = "grey70") +
scale_y_discrete(labels = road_defect_labels) +
labs(
  title = "Absolute Unfallhäufigkeit nach Straßenschäden",
  x = "Anzahl Unfälle",
  y = "Straßenschaden"
) +
theme_minimal()

dataset.roadDefectAnalysis.plot_absolute
```




Abbildung 12: Absolute Unfallhäufigkeit nach Straßenschäden

Die absolute Verteilung zeigt eine extreme Dominanz der Kategorie *Keine Defekte* mit über 171.000 Unfällen. Alle anderen Kategorien machen zusammen weniger als 2% der Unfälle aus. Besonders *Trümmer auf Fahrbahn* (139 Unfälle) und *Seitenstreifenschaden* (358 Unfälle) weisen sehr geringe Fallzahlen auf, was bei der Interpretation der Verletzungsraten berücksichtigt werden muss.

4.2.6.2 Relative Unfallschwere

```
dataset.roadDefectAnalysis.plot_injuryRate <- ggplot(
  dataset.roadDefectAnalysis.defect_summary,
  aes(x = verletzungsrage, y = reorder(road_defect, verletzungsrage))
) +
geom_col(fill = "#b00b1e") +
scale_y_discrete(labels = road_defect_labels) +
labs(
  title = "Verletzungsrage nach Straßenschäden",
  x = "Anteil Unfälle mit Verletzten (%)",
  y = "Straßenschaden"
) +
theme_minimal()
```



```
dataset.roadDefectAnalysis.plot_injuryRate
```




Abbildung 13: Verletzungsrate (Anteil der Unfälle mit Personenschäden) nach Straßenschäden

Die Grafik zur relativen Unfallschwere widerlegt die aufgestellte Hypothese weitgehend. Straßen ohne erkennbare Defekte weisen mit etwa 26% nicht die niedrigste Verletzungsrate auf. Tatsächlich zeigen mehrere Schadenskategorien abweichende Muster: Seitenstreifenschäden weisen mit ca. 33% die höchste Verletzungsrate auf, gefolgt von abgenutzten Oberflächen (~30%) und Trümmern auf der Fahrbahn (~29%). Interessanterweise zeigen Spurrillen/Löcher mit nur 19% die niedrigste Verletzungsrate aller Kategorien. Die Kategorie "Sonstige" liegt mit etwa 26% im mittleren Bereich, ist jedoch als Sammelkategorie inhaltlich nicht interpretierbar. Aufgrund der sehr geringen Fallzahlen bei Seitenstreifenschäden (358 Unfälle) und Trümmern auf der Fahrbahn (139 Unfälle) sind diese Werte jedoch statistisch wenig belastbar. Die erwartete eindeutige Korrelation zwischen Straßenschäden und erhöhter Unfallschwere lässt sich in den Daten nicht bestätigen.

Interpretation der Ergebnisse

Die Daten zeigen keinen klaren Zusammenhang zwischen Straßenschäden und Unfallschwere. Die Hypothese muss verworfen werden. Eine mögliche Erklärung wäre, dass sichtbare Straßenschäden von Verkehrsteilnehmenden wahrgenommen werden und zu angepasstem Fahrverhalten führen – diese Interpretation bleibt jedoch spekulativ, da der Datensatz keine Informatio-

nen zum Fahrverhalten enthält. Zudem ist bei den meisten Schadenszuständen die statistische Basis aufgrund geringer Fallzahlen eingeschränkt, sodass die Ergebnisse mit Vorsicht zu interpretieren sind.

4.2.7 Fazit:

Die Analyse zeigt ein deutliches Vulnerability-Gefälle: Fußgänger (89-93%) und Radfahrer (70-78%) tragen ein strukturell höheres Verletzungsrisiko als motorisierte Verkehrsteilnehmende – weitgehend unabhängig von Infrastruktur und Verkehrsregelung. Bei motorisierten Unfällen reduzieren bauliche Trennung (Divided Roads: 24% vs. Two-Way: 28%) und klare Verkehrskontrollen die Verletzungsraten messbar, insbesondere bei kritischen Kollisionsarten wie Frontal- (*Head On*) und Seitenaufprall (*Angle*). Kreuzungen bleiben mit 32% Verletzungsrate die gefährlichsten Straßenabschnitte.

Die Hypothesen zu geometrischer Komplexität wurden nur teilweise bestätigt: Während Kurven mit Höhenunterschieden (bis 37%) tatsächlich gefährlicher sind, weisen ebene Kurven (22%) überraschend niedrige Raten auf. Die vermutete Korrelation zwischen Straßenschäden und Unfallschwere konnte nicht bestätigt werden. Methodisch sind viele Befunde durch geringe Fallzahlen (z.B. Kurve auf Bergkuppe: $n=53$) eingeschränkt. Insgesamt zeigt sich: Infrastrukturelle Gestaltung beeinflusst die Unfallschwere bei motorisierten Verkehrsteilnehmenden deutlich, während ungeschützte Gruppen strukturell gefährdet bleiben – unabhängig von situativen Faktoren.

4.3 Untersuchung von Wetter und Umgebungsbedingungen

Neben zeitlichen und infrastrukturellen Faktoren beeinflussen auch die Umgebungsbedingungen wie die Wetterlage, die Lichtverhältnisse und der Fahrbahnzustand die Entstehung von Unfällen. Sie wirken sich auf die Sichtweite, die Reaktionsfähigkeit und die physikalischen Eigenschaften des Fahrzeugs aus und bestimmen somit die Wahrscheinlichkeit von Unfällen und die Schwere der Unfallfolgen.

In diesem Abschnitt wird untersucht, ob bestimmte Umweltbedingungen systematisch mit einer erhöhten relativen Unfallschwere einhergehen. Wie bei den vorherigen Analysen wird dabei bewusst zwischen absoluter Unfallohäufigkeit und relativer Unfallschwere unterschieden: Im Fokus steht nicht die Frage, unter welchen Bedingungen die meisten Unfälle auftreten, sondern unter welchen Bedingungen ein Unfall mit höherer Wahrscheinlichkeit zu Personenschäden führt.

Als Maß für die Unfallschwere dient erneut die binäre Variable `has_injury`, die angibt, ob es bei einem Unfall Verletzte gab oder nicht. Wie zuvor ist die Analyse deskriptiver Natur und soll das Entdecken systematischer Muster unterstützen, und keine kausalen Schlussfolgerungen erzielen.

4.3.1 Wetter und Unfallschwere

Der Einfluss von Wetterbedingungen auf Verkehrsunfälle scheint auf den ersten Blick naheliegend, sollte jedoch differenziert betrachtet werden. Das Wetter wirkt sich nicht als einheitlicher Faktor auf das Unfallgeschehen aus, sondern beeinflusst verschiedene Aspekte der Fahrsituation, z.B. die Sichtverhältnisse, die Beschaffenheit der Fahrbahn und die Fahrzeugkontrolle, welche wiederum zu veränderten Bremswegen oder einer eingeschränkten Stabilität bei Nässe, Schnee oder Eis führen können. Gleichzeitig beeinflussen Wetterlagen auch das Verkehrsaufkommen und das Fahrverhalten. Bei ungünstigen Bedingungen wird häufig vorsichtiger gefahren oder auf Fahrten verzichtet, wodurch sich die Anzahl der Unfälle reduzieren kann. Diese Anpassungen betreffen jedoch nicht zwangsläufig die Schwere der Unfälle, wenn es dennoch zu einer Kollision kommt. Vor diesem Hintergrund liegt der Fokus der Analyse nicht auf der absoluten Unfallhäufigkeit bei bestimmten Wetterlagen, sondern auf der Frage, ob sich unter unterschiedlichen Wetterbedingungen systematische Unterschiede in der Unfallschwere zeigen. Untersucht wird, ob die Wahrscheinlichkeit von Personenschäden zwischen den Wetterkategorien variiert, unabhängig davon, wie häufig diese Bedingungen auftreten.

Datenbasis: Verteilung der Wetterbedingungen

Bevor die Unfallschwere analysiert wird, soll zunächst die Häufigkeitsverteilung der Wetterkategorien im unbereinigten Datensatz betrachtet werden, um die zugrundeliegende Datenbasis besser zu verstehen und die statistische Belastbarkeit der einzelnen Kategorien einzuschätzen.

```
dataset %>%  
  count(weather_condition) %>%  
  mutate(  
    Wetterbedingung = recode(  
      weather_condition,  
      "CLEAR" = "Klar",  
      "CLOUDY/OVERCAST" = "Bewölkt",  
      "RAIN" = "Regen",  
      "SNOW" = "Schnee",  
      "SLEET/HAIL" = "Schneeregen/Hagel",  
      "FREEZING RAIN/DRIZZLE" = "Gefrierender Regen/Niesel",  
      "FOG/SMOKE/HAZE" = "Nebel/Rauch/Dunst",  
      "BLOWING SNOW" = "Treibschnee",  
      "SEVERE CROSS WIND GATE" = "Starker Seitenwind",  
      "BLOWING SAND, SOIL, DIRT" = "Aufgewirbelter Sand/Staub",  
      "OTHER" = "Sonstige",  
      "UNKNOWN" = "Unbekannt"  
    )  
  )
```

Tabelle 5: Häufigkeitsverteilung der Wetterbedingungen im unbereinigten Datensatz

Wetterbedingung	Anzahl Unfälle
Klar	164700
Regen	21703
Bewölkt	7533
Schnee	6871
Unbekannt	6534
Sonstige	627
Gefrierender Regen/Niesel	510
Nebel/Rauch/Dunst	360
Schneeregen/Hagel	308
Treibschnee	127
Starker Seitenwind	32
Aufgewirbelter Sand/Staub	1

```

) %>%
select(
  Wetterbedingung,
  `Anzahl Unfälle` = n
) %>%
arrange(desc(`Anzahl Unfälle`)) %>%
gt() %>%
tab_style(
  style = cell_text(weight = "bold"),
  locations = cells_column_labels()
)

```

Wie diese Übersicht zeigt, wird der Datensatz von den Wetterkategorien *Klar* und *Regen* dominiert. Extreme Wetterlagen wie *Aufgewirbelter Sand/Staub* und *Starker Seitenwind* treten hingegen nur sehr selten auf und sind entsprechend schwach besetzt. Dies muss bei der Interpretation der Ergebnisse berücksichtigt werden, da eine unzureichende Datenlage die statistische Belastbarkeit der Kategorie vermindert.

Die Kategorie *Sonstige* fasst Wetterbedingungen zusammen, für die bei der Datenerhebung keine passende Kategorie zur Auswahl stand. Daher ist sie inhaltlich nur eingeschränkt interpretierbar.

Die Kategorie *Unbekannt* kennzeichnet Fälle, in denen keine Wetterinformation erhoben wurde. Diese Beobachtungen wurden im Bereinigungsschritt in Kapitel 3 aus dem Datensatz für die Analyse entfernt, da sie keiner Wetterkategorie zugeordnet werden können und somit die Berechnung und den Vergleich wetterbezogener Unfallraten verfälschen können.

Methodisches Vorgehen

Zur Analyse des Einflusses der Wetterlage werden alle Unfälle mit einer gültigen Angabe zur Wetterbedingung (`weather_condition`) berücksichtigt. Für jede Wetterkategorie wird sowohl die Gesamtzahl der Unfälle als auch der relative Anteil der Unfälle mit Personenschäden ermittelt. Die Verletzungsrate ergibt sich dabei als Mittelwert der binären Variable `has_injury` und kann direkt als prozentualer Anteil interpretiert werden. Dieses Vorgehen ermöglicht den Vergleich der Gefährlichkeit verschiedener Wetterlagen unabhängig von deren Auftrittshäufigkeit.

```
dataset.weatherAnalysis.weather_summary <- dataset.clean %>%  
  filter(!is.na(weather_condition), !is.na(has_injury)) %>%  
  group_by(weather_condition) %>%  
  summarize(  
    anzahl_unfaelle = n(),  
    verletzungsrage = mean(has_injury) * 100  
  ) %>%  
  arrange(desc(verletzungsrage))
```

4.3.1.1 Absolute Unfallhäufigkeit

Zunächst wird die absolute Anzahl der Unfälle pro Wetterkategorie in einem Balkendiagramm dargestellt. Dieses entspricht inhaltlich der Aufstellung in Tabelle 5, aber dient der besseren Visualisierung der absoluten Unfallhäufigkeiten und soll einen direkten Vergleich mit dem darauf folgenden Diagramm zur relativen Unfallschwere ermöglichen.

```
weather_labels <- c(  
  "CLEAR" = "Klar",  
  "CLOUDY/OVERCAST" = "Bewölkt",  
  "RAIN" = "Regen",  
  "SNOW" = "Schnee",  
  "SLEET/HAIL" = "Schneeregen/Hagel",  
  "FREEZING RAIN/DRIZZLE" = "Gefrierender Regen/Niesel",  
  "FOG/SMOKE/HAZE" = "Nebel/Rauch/Dunst",  
  "BLOWING SNOW" = "Treibschnee",  
  "SEVERE CROSS WIND GATE" = "Starker Seitenwind",  
  "BLOWING SAND, SOIL, DIRT" = "Aufgewirbelter Sand/Staub",  
  "OTHER" = "Sonstige"  
)  
  
dataset.weatherAnalysis.plot_absoluteAccidentNumber <- ggplot(  
  dataset.weatherAnalysis.weather_summary,
```

```

    aes(x = anzahl_unfaelle,
        y = reorder(weather_condition, anzahl_unfaelle))
  ) +
  geom_col(fill = "grey70") +
  scale_y_discrete(labels = weather_labels) +
  labs(
    title = "Absolute Unfallhäufigkeit nach Wetterlage",
    x = "Anzahl Unfälle",
    y = "Wetterbedingung"
  ) +
  theme_minimal()

dataset.weatherAnalysis.plot_absoluteAccidentNumber

```




Abbildung 14: Absolute Unfallhäufigkeit nach Wetterlage

Die Darstellung verdeutlicht noch einmal die starke Dominanz günstiger Wetterbedingungen bei Unfällen: Diese machen den überwiegenden Teil des Datensatzes aus, während extreme Wetterlagen seltener sind.

4.3.1.2 Relative Unfallschwere

Im nächsten Schritt wird die Verletzungsrate für jede Wetterkategorie dargestellt. Diese wurde zuvor als Anteil der Unfälle mit Verletzten an allen Unfällen der jeweiligen Wetterkategorie berechnet.

```
dataset.weatherAnalysis.plot_injuryRate <- ggplot(  
  dataset.weatherAnalysis.weather_summary,  
  aes(x = verletzungsrage, y = reorder(weather_condition, verletzungsrage))  
) +  
  geom_col(fill = "#b00b1e") +  
  scale_y_discrete(labels = weather_labels) +  
  labs(  
    title = "Verletzungsrate nach Wetterlage",  
    x = "Anteil Unfälle mit Verletzten (%)",  
    y = "Wetterbedingung"  
  ) +  
  theme_minimal()
```

dataset.weatherAnalysis.plot_injuryRate




Abbildung 15: Verletzungsrate (Anteil der Unfälle mit Personenschäden) nach Wetterlage

Interpretation der Ergebnisse

Die Analyse zeigt deutliche Unterschiede in der relativen Unfallschwere zwischen den verschiedenen Wetterkategorien. Besonders hohe Verletzungsraten treten bei seltenen oder extremen Wetterlagen wie *Schneeregen/Hagel*, *Gefrierender Regen/Niesel* sowie *Nebel/Rauch/Dunst* auf. In diesen Kategorien liegt der Anteil der Unfälle mit Personenschäden bei etwa 30 Prozent oder mehr.

Demgegenüber weisen die Kategorien *Klar* und *Bewölkt* trotz sehr hoher absoluter Unfallzahlen deutlich niedrigere Verletzungsraten auf. Der Vergleich mit der absoluten Unfallhäufigkeit macht somit deutlich, dass hohe Unfallzahlen nicht mit hoher Unfallschwere gleichzusetzen sind.

Die Kategorie *Regen* nimmt eine Zwischenstellung ein: Sie ist häufig vertreten und gleichzeitig mit einer relativ hohen Verletzungsrate verbunden. Dies deutet darauf hin, dass bereits moderate Einschränkungen der Sicht oder der Fahrbahnhaltung die Unfallfolgen verschärfen können.

Auffällig ist, dass die Wetterlagen *Schnee*, *Treibschnee* und *Starker Seitenwind* trotz der grundsätzlich erschwerten Fahrbedingungen vergleichsweise niedrigere Verletzungsraten aufweisen als einige häufigere Wetterlagen. Ein plausibler Erklärungsansatz hierfür ist die situationsbedingte Anpassung des Fahrverhaltens: Bei offensichtlich widrigen Bedingungen reduzieren viele Verkehrsteilnehmende ihre Geschwindigkeit, erhöhen die Abstände zueinander und vermeiden riskante Fahrmanöver. Dadurch sinkt zwar nicht unbedingt die Unfallwahrscheinlichkeit, aber die Aufprallenergie und somit die Schwere der Unfallfolgen.

Die sehr geringe Verletzungsrate in der Kategorie *Aufgewirbelter Sand/Staub* ist vor dem Hintergrund der äußerst geringen Fallzahlen zu interpretieren (siehe Tabelle 5). Mit nur einer beobachteten Unfallmeldung ist diese Kategorie statistisch nicht stabil und erlaubt keine belastbaren Aussagen zur tatsächlichen Gefährlichkeit dieser Wetterlage. Der niedrige Wert spiegelt daher mit hoher Wahrscheinlichkeit einen Stichprobeneffekt wider und nicht ein systematisch geringes Risiko.

4.3.2 Lichtverhältnisse und Unfallschwere

Neben der Wetterlage sind die Lichtverhältnisse ein zentraler Einflussfaktor für das Unfallgeschehen. Sie beeinflussen maßgeblich die Sichtweite, den Kontrast zwischen Verkehrsteilnehmenden und Umgebung sowie die Wahrnehmung von Gefahren und Verkehrsregelungen. Insbesondere bei Dämmerung oder Dunkelheit kann die visuelle Informationsverarbeitung eingeschränkt sein, was sich wiederum auf die Reaktionszeiten und Fahrentscheidungen auswirken kann. In diesem Abschnitt wird untersucht, ob und in welchem Ausmaß unterschiedliche Lichtverhältnisse mit einer erhöhten relativen Unfallschwere einhergehen. Analog zur Analyse der Wetterbedingungen wird auch hier zwischen absoluter Unfallhäufigkeit und relativer Unfallschwere unterschieden. Der Fokus liegt nicht auf der Frage, unter welchen Lichtverhältnissen die meisten Unfälle auftreten, sondern darauf, bei welchen Lichtbedingungen ein Unfall mit höherer Wahrscheinlichkeit zu Personenschäden führt. Als Maß für die Unfallschwere dient erneut die binäre Variable `has_injury`, die angibt, ob ein Unfall mit Verletzten verbunden war oder nicht.

Tabelle 6: Häufigkeitsverteilung der Lichtverhältnisse im unbereinigten Datensatz

Lichtverhaeltnis	Anzahl Unfaelle
Tageslicht	134109
Dunkelheit (beleuchtet)	53378
Dunkelheit (unbeleuchtet)	7436
Dämmerung	6323
Unbekannt	4336
Morgendämmerung	3724

Datenbasis: Verteilung der Lichtverhältnisse

Zunächst wird die Häufigkeitsverteilung der Lichtverhältnisse im unbereinigten Datensatz betrachtet. So lässt sich die zugrunde liegende Datenbasis verstehen und die statistische Belastbarkeit der einzelnen Kategorien einschätzen.

```
dataset %>%
  count(lightning_condition) %>%
  mutate(
    Lichtverhaeltnis = recode(
      lightning_condition,
      "DAYLIGHT" = "Tageslicht",
      "DARKNESS, LIGHTED ROAD" = "Dunkelheit (beleuchtet)",
      "DARKNESS" = "Dunkelheit (unbeleuchtet)",
      "DUSK" = "Dämmerung",
      "DAWN" = "Morgendämmerung",
      "UNKNOWN" = "Unbekannt"
    )
  ) %>%
  select(
    Lichtverhaeltnis,
    `Anzahl Unfaelle` = n
  ) %>%
  arrange(desc(`Anzahl Unfaelle`)) %>%
  gt() %>%
  tab_style(
    style = cell_text(weight = "bold"),
    locations = cells_column_labels()
  )
```

Die Verteilung der Lichtverhältnisse zeigt, dass die meisten Unfälle bei Tageslicht sowie bei Dunkelheit auf beleuchteten Straßen auftreten. Die übrigen Kategorien wie *Dunkelheit (un-*

beleuchtet), *Dämmerung* und *Morgendämmerung* sind zwar weniger häufig vertreten, weisen jedoch ebenfalls ausreichende Fallzahlen auf, sodass die Analysen statistisch belastbar sind.

Methodisches Vorgehen

In die Analyse werden alle Unfälle mit gültigen Angaben zu den Lichtverhältnissen (`lighting_condition`) und zur Unfallschwere (`has_injury`) einbezogen. Für jede Kategorie der Lichtverhältnisse wird sowohl die absolute Anzahl der Unfälle als auch die Verletzungsrate berechnet. Letztere ermöglicht den Vergleich der relativen Unfallschwere zwischen den Kategorien, unabhängig davon, wie häufig die jeweiligen Lichtverhältnisse auftreten.

```
dataset.lightingAnalysis.lighting_summary <- dataset.clean %>%
  filter(!is.na(lighting_condition), !is.na(has_injury)) %>%
  group_by(lighting_condition) %>%
  summarize(
    anzahl_unfaelle = n(),
    verletzungsrate = mean(has_injury) * 100
  ) %>%
  arrange(desc(verletzungsrate))
```

4.3.2.1 Absolute Unfallhäufigkeit

Zunächst erfolgt die Visualisierung der in Tabelle 6 dargestellten absoluten Unfallhäufigkeiten, um den Vergleich mit der im darauf folgenden Diagramm dargestellten relativen Unfallschwere zu erleichtern.

```
lighting_labels <- c(
  "DAYLIGHT" = "Tageslicht",
  "DARKNESS, LIGHTED ROAD" = "Dunkelheit (beleuchtet)",
  "DARKNESS" = "Dunkelheit (unbeleuchtet)",
  "DUSK" = "Dämmerung",
  "DAWN" = "Morgendämmerung"
)

dataset.lightingAnalysis.plot_absolute <- ggplot(
  dataset.lightingAnalysis.lighting_summary,
  aes(x = anzahl_unfaelle,
      y = reorder(lighting_condition, anzahl_unfaelle))
) +
  geom_col(fill = "grey70") +
  scale_y_discrete(labels = lighting_labels) +
  labs(
```

```

title = "Absolute Unfallhäufigkeit nach Lichtverhältnissen",
x = "Anzahl Unfälle",
y = "Lichtverhältnisse"
) +
theme_minimal()

dataset.lightingAnalysis.plot_absolute

```




Abbildung 16: Absolute Unfallhäufigkeit nach Lichtverhältnissen

Die deutlich geringeren Unfallzahlen in den Kategorien *Dämmerung*, *Morgendämmerung* und *Dunkelheit (unbeleuchtet)* werden vermutlich durch strukturelle und verhaltensbezogene Faktoren hervorgerufen. Diese Lichtverhältnisse treten nur in relativ kurzen Übergangsphasen auf oder fallen in Tageszeiten mit insgesamt geringerem Verkehrsaufkommen. Zudem ist davon auszugehen, dass Verkehrsteilnehmende ihr Fahrverhalten unter offensichtlich ungünstigen Sichtbedingungen anpassen, beispielsweise durch reduzierte Geschwindigkeit und erhöhte Aufmerksamkeit. In Kombination führen diese Faktoren zu einer geringeren Exposition und damit zu niedrigeren absoluten Unfallzahlen. Dies geht jedoch nicht zwangsläufig mit einer geringeren Unfallschwere einher.

4.3.2.2 Relative Unfallschwere

Im nächsten Schritt wird die Verletzungsrate für jede Kategorie der Lichtverhältnisse dargestellt.

```
dataset.lightingAnalysis.plot_injuryRate <- ggplot(  
  dataset.lightingAnalysis.lighting_summary,  
  aes(x = verletzungsrage,  
      y = reorder(lightning_condition, verletzungsrage))  
  ) +  
  geom_col(fill = "#b00b1e") +  
  scale_y_discrete(labels = lightning_labels) +  
  labs(  
    title = "Verletzungsrate nach Lichtverhältnissen",  
    x = "Anteil Unfälle mit Verletzten (%)",  
    y = "Lichtverhältnisse"  
  ) +  
  theme_minimal()  
  
dataset.lightingAnalysis.plot_injuryRate
```




Abbildung 17: Verletzungsrate (Anteil der Unfälle mit Personenschäden) nach Lichtverhältnissen

Wie das Balkendiagramm zur relativen Unfallschwere zeigt, sind Unfälle bei Dunkelheit deutlich häufiger mit Personenschäden verbunden als Unfälle bei Tageslicht. Sowohl beleuchtete

als auch unbeleuchtete Dunkelheit weisen höhere Verletzungsraten auf, wobei die Unterschiede zwischen beiden geringer ausfallen als der Abstand zum Tageslicht. Dies spricht dafür, dass künstliche Beleuchtung die mit Dunkelheit verbundenen Risiken nur teilweise reduziert. Demgegenüber ereignen sich die meisten Unfälle bei Tageslicht, was vermutlich mit dem zu dieser Zeit deutlich höheren Verkehrsaufkommen zusammenhängt. Trotz der hohen absoluten Unfallzahlen ist die Verletzungsrate bei Tageslicht am niedrigsten. Ein Unfall bei guten Sichtverhältnissen endet somit im Durchschnitt seltener mit Personenschäden als ein Unfall unter eingeschränkten Lichtbedingungen. In der Dämmerung und Morgendämmerung gibt es zwar weniger Unfälle, die Verletzungsraten sind jedoch im Vergleich zum Tageslicht erhöht. Dies könnte damit erklärt werden, dass Übergangssituationen mit wechselnden Lichtverhältnissen die visuelle Wahrnehmung erschweren und die Einschätzung von Entfernung und Geschwindigkeiten beeinträchtigen können. Ein Vergleich von absoluter Unfallhäufigkeit und relativer Unfallschwere verdeutlicht noch einmal, dass hohe Unfallzahlen nicht zwangsläufig mit hoher Unfallschwere einhergehen. Insbesondere die Dunkelheit stellt ein zentrales Risikomerkmal für schwere Unfallfolgen dar, während Tageslicht vor allem von einer relativ hohen Unfallhäufigkeit geprägt ist.

4.3.3 Fahrbahnzustand und Unfallschwere

Der Zustand der Fahrbahn beeinflusst durch Faktoren wie reduzierte Haftung, verlängerte Bremswege oder eingeschränkte Lenkbarkeit die Fahrdynamik eines Fahrzeugs und damit die Häufigkeit und Schwere von Unfällen. Gleichzeitig ist auch hier davon auszugehen, dass viele Verkehrsteilnehmende auf offensichtlich ungünstige Fahrbedingungen mit erhöhter Aufmerksamkeit und Vorsicht reagieren, was wiederum die Datenverteilungen der Unfallhäufigkeit und -schwere auf verschiedene Weise beeinflusst. Ziel dieses Abschnitts ist daher, zu untersuchen, ob und in welchem Ausmaß unterschiedliche Fahrbahnzustände mit einer erhöhten relativen Unfallschwere einhergehen. Analog zu den vorherigen Analysen wird zwischen absoluter Unfallhäufigkeit und relativer Unfallschwere unterschieden. Der Fokus liegt darauf, wie schwer Unfälle ausfallen, wenn sie unter bestimmten Fahrbahnbedingungen auftreten, unabhängig davon, wie häufig diese Bedingungen zu Unfällen führen. Als Maß für die Unfallschwere dient erneut die binäre Variable `has_injury`, die angibt, ob ein Unfall mit Personenschäden verbunden war.

Datenbasis: Verteilung der Fahrbahnzustände

Zunächst wird die Häufigkeitsverteilung der Fahrbahnzustände betrachtet. Dieser Schritt dient der Einordnung der Datenbasis und erlaubt eine Einschätzung, welche Kategorien ausreichend häufig auftreten, um statistisch belastbare Aussagen zur Unfallschwere zu ermöglichen.

```
dataset %>%  
  count(roadway_surface_cond) %>%  
  mutate(
```

Tabelle 7: Häufigkeitsverteilung der Fahrbahnzustände im unbereinigten Datensatz

Fahrbahnzustand	Anzahl Unfälle
Trocken	155905
Nass	32908
Unbekannt	12509
Schnee	6203
Eis	1303
Sonstige	438
Sand/Schmutz	40

```

Fahrbahnzustand = recode(
  roadway_surface_cond,
  "DRY" = "Trocken",
  "WET" = "Nass",
  "SNOW OR SLUSH" = "Schnee",
  "ICE" = "Eis",
  "SAND, MUD, DIRT" = "Sand/Schmutz",
  "OTHER" = "Sonstige",
  "UNKNOWN" = "Unbekannt"
)
) %>%
select(
  Fahrbahnzustand,
  `Anzahl Unfälle` = n
) %>%
arrange(desc(`Anzahl Unfälle`)) %>%
gt() %>%
tab_style(
  style = cell_text(weight = "bold"),
  locations = cells_column_labels()
)

```

Die Verteilung zeigt, dass trockene Fahrbahnverhältnisse am häufigsten vertreten sind, gefolgt von nassen Straßen. Bei Schnee-, Eis- und sonstigen Sonderzuständen wurden deutlich weniger Unfälle aufgenommen. Und für die Kategorie *Sand/Schmutz* stehen lediglich 40 Beobachtungen zur Verfügung, was bei der Interpretation der Ergebnisse berücksichtigt werden muss. Die Beobachtungen der Kategorie *Unbekannt* wurden wie bei den vorigen Analysen im Bereinigungsschritt in Kapitel 3 aus dem Datensatz entfernt, da sie keine inhaltliche Interpretation erlauben und Analysen verfälschen können.

Methodisches Vorgehen

Wie bei den vorigen Analysen werden auch hier nur Unfallbeobachtungen mit gültigen Angaben zur analysierten Variable einbezogen. Für jede Kategorie des Fahrbahnzustands werden absolute Unfallanzahl und Verletzungsrate berechnet.

```
dataset.roadwayAnalysis.roadway_summary <- dataset.clean %>%  
  filter(!is.na(roadway_surface_cond), !is.na(has_injury)) %>%  
  group_by(roadway_surface_cond) %>%  
  summarize(  
    anzahl_unfaelle = n(),  
    verletzungsrate = mean(has_injury) * 100  
  ) %>%  
  arrange(desc(verletzungsrate))
```

4.3.3.1 Absolute Unfallhäufigkeit

Für eine bessere Visualisierung und Vergleichbarkeit mit dem darauf folgenden Diagramm zur relativen Unfallschwere wird hier zunächst die absolute Unfallhäufigkeit dargestellt.

```
roadway_labels <- c(  
  "DRY" = "Trocken",  
  "WET" = "Nass",  
  "SNOW OR SLUSH" = "Schnee",  
  "ICE" = "Eis",  
  "SAND, MUD, DIRT" = "Sand/Schmutz",  
  "OTHER" = "Sonstige"  
)  
  
dataset.roadwayAnalysis.plot_absolute <- ggplot(  
  dataset.roadwayAnalysis.roadway_summary,  
  aes(x = anzahl_unfaelle, y = reorder(roadway_surface_cond, anzahl_unfaelle))  
) +  
  geom_col(fill = "grey70") +  
  scale_y_discrete(labels = roadway_labels) +  
  labs(  
    title = "Absolute Unfallhäufigkeit nach Fahrbahnzustand",  
    x = "Anzahl Unfälle",  
    y = "Fahrbahnzustand"  
  ) +  
  theme_minimal()  
  
dataset.roadwayAnalysis.plot_absolute
```




Abbildung 18: Absolute Unfallhäufigkeit nach Fahrbahnzustand

4.3.3.2 Relative Unfallschwere

Im nächsten Schritt wird die Verletzungsrate für jeden Fahrbahnzustand dargestellt, welche den Vergleich der Unfallschwere der verschiedenen Kategorien unabhängig von deren Unfallhäufigkeit erlaubt.

```
dataset.roadwayAnalysis.roadway_injuryRate <- ggplot(
  dataset.roadwayAnalysis.roadway_summary,
  aes(x = verletzungsrage, y = reorder(roadway_surface_cond, verletzungsrage))
) +
geom_col(fill = "#b00b1e") +
scale_y_discrete(label = roadway_labels) +
labs(
  title = "Verletzungsrate nach Fahrbahnzustand",
  x = "Anteil Unfälle mit Verletzten (%)",
  y = "Fahrbahnzustand"
) +
theme_minimal()

dataset.roadwayAnalysis.roadway_injuryRate
```





Abbildung 19: Verletzungsrate (Anteil der Unfälle mit Personenschäden) nach Fahrbahnzustand

Interpretation der Ergebnisse

Die Grafik zur relativen Unfallschwere nach Fahrbahnzustand zeigt, dass nasse Fahrbahnen sowie die Kategorie *Sonstige* die höchsten Verletzungsraten aufweisen, während trockene Fahrbahnen trotz der größten absoluten Unfallohftigkeit eine niedrige relative Unfallschwere zeigen. Damit bestätigt sich erneut das bereits bei Wetter- und Lichtverhältnissen beobachtete Muster: Hohe absolute Unfallzahlen gehen nicht zwangsläufig mit einer hohen Unfallschwere einher. Auffällig ist, dass die Kategorien *Schnee* und *Eis* im Vergleich zu *Nass* und *Trocken* geringere Verletzungsraten aufweisen, obwohl diese Zustände objektiv als gefährlich gelten. Analog zur Analyse der Wettereinflüsse könnte dies durch eine situationsbedingte Anpassung des Fahrverhaltens begründet sein.

Die relativ hohe Verletzungsrate bei nasser Fahrbahn ist im Zusammenspiel mit ihrer hohen absoluten Häufigkeit bei Unfällen besonders relevant. Scheinbar wird eine nasse Fahrbahn im Gegensatz zu Schnee und Eis weniger stark als Gefahr wahrgenommen und birgt dadurch ein besonders hohes Risiko für schwere Unfälle.

Bei selten vertretenen Kategorien wie *Sand/Schmutz* wurde eine relativ hohe Unfallschwere beobachtet, welche jedoch wegen der geringen Anzahl an Beobachtungen keine aussagekräftige Interpretation erlaubt (siehe Tabelle Tabelle 7).

4.3.4 Fazit zu Wetter, Lichtverhältnissen und Fahrbahnzustand

Insgesamt zeigt die gemeinsame Betrachtung von absoluter Unfallhäufigkeit und relativer Unfallschwere über Wetter, Lichtverhältnisse und Fahrbahnzustand hinweg ein konstantes Bild: Nicht die objektiv schwierigsten Bedingungen sind unbedingt mit der höchsten Unfallschwere verbunden, sondern jene Situationen, in denen die Einschränkungen moderat sind und das Fahrverhalten scheinbar weniger stark angepasst wird.

5 Zusammenfassung und Schlussfolgerung

Ziel dieser Arbeit war es, zu untersuchen, welche äußeren Bedingungen und situativen Merkmale mit der Schwere von Verkehrsunfällen in Zusammenhang stehen. Der Fokus lag dabei nicht auf der reinen Unfallhäufigkeit, sondern auf der relativen Unfallschwere, gemessen als Anteil der Unfälle mit Personenschaden (`has_injury`). Analysiert wurden zeitliche Faktoren, infrastrukturelle Merkmale sowie Umweltbedingungen wie Wetterlage, Lichtverhältnisse und Fahrbahnzustand.

5.1 Vergleich der Ergebnisse mit den ursprünglichen Erwartungen

Ausgangspunkt der Analyse war die Annahme, dass ungünstige Umwelt- und Sichtbedingungen sowie komplexe Verkehrssituationen mit einer höheren Unfallschwere einhergehen, während unter günstigen Bedingungen zwar viele Unfälle auftreten, diese jedoch überwiegend glimpflich verlaufen. Diese Annahmen werden durch die Ergebnisse weitgehend bestätigt, zugleich aber in manchen Punkten differenziert.

Über alle Analysen hinweg zeigt sich, dass absolute Unfallhäufigkeit und relative Unfallschwere nicht gleichzusetzen sind. Die meisten Unfälle ereignen sich bei Tageslicht, klarem Wetter und trockener Fahrbahn, was vor allem auf das höhere Verkehrsaufkommen unter diesen Bedingungen zurückzuführen ist. Gleichzeitig weisen diese Unfälle im Durchschnitt eine geringere Verletzungsrate auf. Damit bestätigt sich die Erwartung, dass günstige Rahmenbedingungen zwar viele Unfälle begünstigen, diese jedoch überwiegend glimpflich verlaufen.

Demgegenüber weisen ungünstige Bedingungen häufig eine höhere relative Unfallschwere auf, auch wenn sie seltener auftreten. Dies gilt insbesondere für Nachtstunden und bestimmte Wetterlagen wie gefrierenden Regen oder Nebel. Die Erwartung, dass eingeschränkte Sichtverhältnisse und erschwerte Umweltbedingungen das Risiko schwerer Unfallfolgen erhöhen, wird damit grundsätzlich bestätigt.

5.2 Differenzierende und unerwartete Erkenntnisse

Gleichzeitig zeigen die Ergebnisse mehrere kontraintuitive Muster. Entgegen der anfänglichen Intuition weisen extreme Bedingungen wie Schnee, Eis oder starker Seitenwind teilweise nied-

rigere Verletzungsraten auf als moderat ungünstige Bedingungen wie Regen, Dunkelheit oder nasse Fahrbahnen. Dies deutet auf eine situationsbedingte Anpassung des Fahrverhaltens hin: Offensichtlich gefährliche Bedingungen gehen häufig mit angepasstem Fahrverhalten einher, während moderat einschränkende Bedingungen tendenziell mit höheren Verletzungsraten verbunden sind, da Gefahren möglicherweise unterschätzt werden und dadurch schwere Unfallfolgen begünstigen.

Auch die zeitliche Analyse relativiert die ursprünglichen Erwartungen. Erwartet wurde, dass Zeiten mit hohem Verkehrsaufkommen zugleich die höchste Unfallschwere aufweisen. Die Ergebnisse zeigen jedoch ein anderes Muster: Zwar konzentriert sich das Unfallaufkommen auf den Nachmittagsverkehr, die relative Unfallschwere ist hingegen nachts und am Wochenende am höchsten. Die ergänzende Analyse alkoholbedingter Unfälle macht deutlich, dass diese Zeiträume eng mit riskantem Fahrverhalten verbunden sind. Damit zeigten die Ergebnisse, dass die erhöhte nächtliche Unfallschwere nicht primär durch zeitliche oder äußere Rahmenbedingungen erklärbar ist, sondern wesentlich durch verhaltensbezogene Faktoren geprägt wird.

5.3 Verkehrsinfrastruktur und Unfalltypen

Die Analyse der Verkehrssituation bestätigt die Erwartung, dass komplexe Verkehrsräume mit einer höheren Unfallschwere verbunden sind. Kreuzungen und nicht baulich getrennte Straßen weisen deutlich höhere Verletzungsraten auf als Einbahnstraßen oder getrennte Fahrbahnen. Besonders Frontal- und Seitenkollisionen gehen mit hohen Verletzungsraten einher, was die Schutzwirkung baulicher getrennter Straßen unterstreicht.

Besonders eindeutig sind die Ergebnisse für ungeschützte Verkehrsteilnehmende. Unfälle mit Fußgänger:innen und Radfahrenden enden nahezu unabhängig vom Straßentyp oder der Verkehrsregelung häufig mit Verletzungen. Dies bestätigt ihre strukturelle Verwundbarkeit im Straßenverkehr und zeigt, dass Verkehrsregelungen allein nicht ausreichen, um die Unfallschwere für diese Gruppen wirksam zu reduzieren.

5.4 Methodische Einordnung und Gesamtfazit

Die Ergebnisse zeigen insgesamt, dass die Schwere von Unfällen nicht durch einzelne Faktoren erklärbar ist, sondern aus dem Zusammenspiel von Umweltbedingungen, Infrastruktur und menschlichem Verhalten entsteht. Bei dieser Analyse handelt es sich um eine deskriptive Analyse, aus der keine kausalen Schlüsse gezogen werden können. Zudem ist die absolute Unfallhäufigkeit stark vom Verkehrsaufkommen abhängig, sodass sie nur eingeschränkt Aussagen über das tatsächliche Risiko erlaubt. Für eine fundiertere Risikobewertung wäre es notwendig, die Ergebnisse in Relation zur Verkehrsdichte zu bewerten. Zusammenfassend zeigt die Analyse, dass schwere Verkehrsunfälle vor allem dort auftreten, wo vermutlich Risiken unterschätzt werden oder mehrere ungünstige Faktoren zusammenkommen. Die klare Trennung zwischen Unfallhäufigkeit und Unfallschwere erweist sich als zentral für das Verständnis des Unfallgeschehens und liefert wichtige Ansatzpunkte für gezielte Präventionsmaßnahmen.

Quellen

Datensatz: Oktay Örddekçi, „Traffic Accidents“. Kaggle-Datensatz. Zugriff am 23. Oktober 2025. Verfügbar unter: <https://www.kaggle.com/datasets/oktayrdeki/traffic-accidents>

Wickham, H. et al. (2019). *Welcome to the tidyverse*. Journal of Open Source Software, 4(43), 1686. <https://doi.org/10.21105/joss.01686>

Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York.

Wickham, H. et al. (2023). *dplyr: A Grammar of Data Manipulation*. R package version 1.1.4. <https://CRAN.R-project.org/package=dplyr>

Grolemund, G. & Wickham, H. (2011). *Dates and Times Made Easy with lubridate*. Journal of Statistical Software, 40(3), 1–25. R package version 1.9.4. <https://CRAN.R-project.org/package=lubridate>

Waring, E. et al. (2022). *skimr: Compact and Flexible Summaries of Data*. R package version 2.2.2. <https://CRAN.R-project.org/package=skimr>

Pedersen, T. L. (2020). *patchwork: The Composer of Plots*. R package version 1.3.2. <https://CRAN.R-project.org/package=patchwork>

Iannone, R., Cheng, J., Schloerke, B., Hughes, E., & Seo, J. (2024). *gt: Easily Create Presentation-Ready Display Tables*. R package version 1.2.0. <https://CRAN.R-project.org/package=gt>